

PART6 非监督式特征提取与低维可视化

2024-05-25

掌握:

1. 理解什么是特征提取? 什么是非监督式特征提取?
2. 什么是线性/非线性特征提取?
3. 理解样本协方差矩阵的本征值与本征列向量的意义。
各主成分的分布方差?
4. PCA的全称?
5. 掌握利用PCA进行特征提取或特征降维的基本实现过程。如何根据累积方差解释比确定特征提取的数目? 如何用PCA实现样本数据的低维可视化?
6. 理解并能够使用t-SNE进行数据的低维可视化。

1 给定观测样本集 $D = \{x_i, i=1, \dots, N\}$, 其中 $x_i \in R^3$. 请结合该样本集, 设计一个基于主成分分析的特征降维方法, 以便基于该算法, 提取原始空间任意观测样本 $x \in R^3$ 的第1、第2主成分.

解:

step1. 基于样本集 D , 估计**样本中心** μ 及**协方差矩阵** Σ .

$$\hat{\mu} = \frac{1}{N} \sum_{i=1}^N x_i \quad \hat{\Sigma} = \frac{1}{N} \sum_{i=1}^N (x_i - \hat{\mu})(x_i - \hat{\mu})^T$$

step2. 确定 Σ 的 $p=3$ 个**本征值**及**本征向量**.

得 p 个本征值 $\lambda_1 \geq \lambda_2 \geq \lambda_3$

对应本征向量 $a_i, i=1, 2, 3$

step3. 确定 3×2 的变换矩阵 $A_r = [a_1 \ a_2]$

step4. 对于任意观测 x , 提取该样本的前两个主成分: $\xi_r = A_r^T (x - \hat{\mu})$

2. 给定数据集 $D = \{x_i, i=1, \dots, m\}$, 其中 $x_i \in R^d$. 请结合该样本集 D , 设计一个基于主成分分析法的特征降维算法, 以便基于该方法将任意观测 $x \in R^d$ 的降至 r

维. 请详细给出有关步骤和必要表达式.

解:

step1. 基于样本集 D , 估计**样本中心** μ 及**协方差矩阵** Σ .

$$\hat{\mu} = \frac{1}{N} \sum_{i=1}^N \mathbf{x}_i \quad \hat{\Sigma} = \frac{1}{N} \sum_{i=1}^N (\mathbf{x}_i - \hat{\mu})(\mathbf{x}_i - \hat{\mu})^T$$

step2. 确定 $\hat{\Sigma}$ 的前 r ($r < d$) 个最大**本征值**及**本征向量**.

$$\text{得前 } r \text{ 个本征值} \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_r$$

$$\text{对应本征向量} \quad \mathbf{a}_i, i = 1, \dots, r$$

step3. 确定 $d \times r$ 的变换矩阵 $\mathbf{A}_r = [\mathbf{a}_1 \quad \mathbf{a}_2 \quad \dots \quad \mathbf{a}_r]$

step4. 对于任意观测 $\mathbf{x}$, 提取该样本 r 维新的特征向量: $\xi_r = \mathbf{A}_r^T (\mathbf{x} - \hat{\mu})$

3. 给定数据集 $D = \{\mathbf{x}_i, i = 1, \dots, m\}$, 其中 $\mathbf{x}_i \in R^d$. 请结合该样本集 D , 设计一个基于主成分分析法的特征降维算法, 并满足累积方差解释比不低于0.9, 请确定新的特征空间特征维数 r . 请详细给出有关步骤和必要表达式.

3. 给定数据集 $D = \{\mathbf{x}_i, i = 1, \dots, m\}$, 其中 $\mathbf{x}_i \in R^d$. 请结合该样本集 D , 设计一个基于主成分分析法的特征降维算法, 并满足累积方差解释比不低于0.9, 请确定新的特征空间特征维数 r . 请详细给出有关步骤和必要表达式.

4. 给定数据集 $D = \{\mathbf{x}_i, i = 1, \dots, m\}$, 其中 $\mathbf{x}_i \in R^d$. 请结合该样本集 D , 请基于主成分分析法实现上述样本集的低维可视化, 请详细给出有关步骤和必要表达式.