

智能软件开发方向基础

第三章 模型的选择与性能评价



张朝晖

2023~2024学年第二学期



序号	内容
1	概述
2	机器学习的基本概念
3	模型的选择与性能评价
4	数据的获取、探索与准备
5	近邻模型-----分类、回归
6	决策树模型-----分类、回归
7	集成学习-----分类、回归
8	(朴素)贝叶斯模型-----分类
9	聚类
10	特征降维及低维可视化(PCA, t-SNE)
11	总复习

课程主要参考书



主要内容

1. 模型的学习能力与泛化能力

学习能力、泛化能力

学习误差(或训练误差)、测试误差


欠学习(欠拟合, underfitting)

过学习(过拟合, overfitting)


2. 交叉验证

3. (基于测试集的)模型评价

二分类/多分类模型、回归模型



1.1 学习能力



- 学习得到的模型关于**训练样本集**的预测能力
- 学习能力的评价：
训练误差(或经验误差)，基于损失函数的经验风险

设学习得到的模型为： $Y = \hat{f}(X)$

训练样本集 $D_{\text{train}} = \{(x_i, y_i), i = 1, \dots, N_{\text{train}}\}$

训练误差： $R_{\text{emp}}(\hat{f}) = \frac{1}{N_{\text{train}}} \sum_{i=1}^{N_{\text{train}}} L(y_i, \hat{f}(x_i))$




河北师范大学软件学院
Software College of Hebei Normal University

面向分类：

注意此处的指示函数

0-1损失 $L(Y, f(X)) = I(Y \neq f(X)) = \begin{cases} 1 & Y \neq f(X) \\ 0 & Y = f(X) \end{cases}$

$$R_{\text{emp}}(\hat{f}) = \frac{1}{N_{\text{train}}} \sum_{i=1}^{N_{\text{train}}} L(y_i, \hat{f}(x_i)) = \frac{1}{N_{\text{train}}} \sum_{i=1}^{N_{\text{train}}} I(y_i, \hat{f}(x_i))$$



面向回归：

训练样本的
预测错误率


平方损失函数 $L(Y, f(X)) = [Y - f(X)]^2$

$$R_{\text{emp}}(\hat{f}) = \frac{1}{N_{\text{train}}} \sum_{i=1}^{N_{\text{train}}} L(y_i, \hat{f}(x_i)) = \frac{1}{N_{\text{train}}} \sum_{i=1}^{N_{\text{train}}} [y_i - \hat{f}(x_i)]^2$$

均方误差MSE



河北师范大学软件学院
Software College of Hebei Normal University



1.2 泛化能力 (generalization ability)

➤ 学得模型关于 **未知样本** 的预测能力

➤ **泛化误差**:

设学习得到的模型为: $Y = \hat{f}(X)$

该模型关于未知样本的预测误差, 即为 **泛化误差**, 它是学习得到的模型的 **期望风险**。

$$R_{\text{exp}}(\hat{f}) = \int_{\mathcal{X} \times \mathcal{Y}} L(y, \hat{f}(x)) P(x, y) dx dy$$

随机变量 X, Y 的函数的数学期望
-- 统计意义上的损失值的平均



河北师范大学软件学院
Software College of Hebei Normal University

1.2 泛化能力 (generalization ability)-续

➤ **测试误差**

泛化误差 难以估计, 实际以 **测试误差** 评价 **模型泛化能力**

给定测试集 $D_{\text{test}} = \{(x_j, y_j), j = 1, \dots, N_{\text{test}}\}$

测试误差:

$$R_{\text{test}}(\hat{f}) = \frac{1}{N_{\text{test}}} \sum_{j=1}^{N_{\text{test}}} L(y_j, \hat{f}(x_j))$$



河北师范大学软件学院
Software College of Hebei Normal University

例：对于“分类问题”的0-1损失，测试误差就是模型关于测试集的**预测错误率**：

$$Err_{test} = \frac{1}{N_{test}} \sum_{i=1}^{N_{test}} I(y_i \neq \hat{f}(x_i))$$

与**预测错误率**对应的是**预测正确率**：


注意此处的
指示函数

$$Acc_{test} = 1 - Err_{test} = \frac{1}{N_{test}} \sum_{i=1}^{N_{test}} I(y_i = \hat{f}(x_i))$$


指示函数举例：

$$I(a=b) = \begin{cases} 1 & \text{若 } a=b \\ 0 & \text{若 } a \neq b \end{cases} \quad I(a \neq b) = \begin{cases} 1 & \text{若 } a \neq b \\ 0 & \text{若 } a=b \end{cases} \quad I(a \geq b) = \begin{cases} 1 & \text{若 } a \geq b \\ 0 & \text{若 } a < b \end{cases}$$

1.3 过拟合与模型选择



当采用规模有限的训练集学习模型时，因模型过于复杂，使得学得模型对**训练集预测性能很好**，而关于**测试集的预测性能很差**，称该现象为**过拟合 (overfitting)**。



例：基于给定的训练集，进行**M次多项式函数拟合**

M次多项式函数：

$$f_M(x; \omega) = \omega_0 + \omega_1 x + \omega_2 x^2 + \cdots + \omega_M x^M = \sum_{j=0}^M \omega_j x^j$$

当M给定时，需要估计的参数向量为：


$$\omega = [\omega_0 \quad \cdots \quad \omega_M]^T$$

训练集 $D_{\text{train}} = \{(x_i, y_i), i = 1, \dots, N_{\text{train}}\}$

测试集 $D_{\text{test}} = \{(x_k, y_k), k = 1, \dots, N_{\text{test}}\}$



河北师范大学软件学院
Software College of Hebei Normal University



采用经验风险最小化策略学习模型：

➤ **损失函数形式**----平均平方误差MSE

➤ **最小二乘准则**

(即：预测误差的平方和最小,或MSE最小)

$$\begin{aligned} E(\omega) &= \frac{1}{N_{\text{train}}} \sum_{i=1}^{N_{\text{train}}} [y_i - \hat{y}_i(\omega)]^2 \\ &= \frac{1}{N_{\text{train}}} \sum_{i=1}^{N_{\text{train}}} [y_i - f_M(x; \omega)]^2 \end{aligned}$$



$$\omega^* = \underset{\omega}{\operatorname{argmin}} E(\omega)$$

如何求解？



河北师范大学软件学院
Software College of Hebei Normal University

讨论：不同模型复杂度 M 的多项式函数拟合结果



随着模型复杂程度(多项式阶数 M)的增加：
模型的训练误差逐渐减小，甚至趋0；
但模型的测试误差先减小，后增加。


M 是多项式函数
拟合的超参数！

→ 多项式函数拟合，应选择合适的 M 值。

对于多项式函数的拟合来说， M 值的确定过程就是模型的选择过程。


右图：

训练误差、测试误差与模型复杂程度之间的关系



随着模型复杂程度的增加：
训练误差逐渐减小，甚至为0；
测试误差先减小，达到最小值后，又增大。

当模型过于复杂时，将产生过拟合。



为避免过拟合，应选择**适当复杂度**的模型。

常采用两种方式

➤ 方式1. 采用结构风险最小化策略，
构建含有**正则项**的目标函数
本讲暂略。

➤ 方式2. 基于**交叉验证**方式的模型选择

交叉验证不仅用于**模型选择**，还用于**最终模型的评价**。



河北师范大学软件学院
Software College of Hebei Normal University

主要内容

1. 模型的学习能力与泛化能力


2. 交叉验证

2.1 数据集的划分方式

2.2 基于交叉验证的模型选择与评价

3. (基于测试集的)模型评价

二分类/多分类模型、回归模型




河北师范大学软件学院
Software College of Hebei Normal University

数据集D的两种层次划分及适用场合

以监督式模型学习为例

如何划分:

- 随机打乱
- 分层随机打乱



Estimation Set

Validation Set

Training Set

Test Set

选择模型（超参数）后再对所有的训练数据进行训练

完整的
模型学习过程

首先，模型的选择（待学习的模型的超参数调节）

训练集 { 估计集(学习)
验证集(评价)

然后，基于选择的模型结构，学习得到最终模型

{ 训练集(超参数固定之后，用于学习最终模型)
测试集(评价最终模型)

主要内容

1. 模型的学习能力与泛化能力


2. 交叉验证

2.1 数据集的划分方式

2.2 基于交叉验证的模型选择与评价

3. (基于测试集的)模型评价

二分类/多分类模型、回归模型、聚类模型的评价



sklearn.model_selection: Model Selection


User guide: See the Cross-validation: evaluating estimator performance, Tuning the hyper-parameters of an estimator and Learning curve sections for further details.

Splitter Classes

<code>model_selection.GroupKFold([n_splits])</code>	K-fold iterator variant with non-overlapping groups.
<code>model_selection.GroupShuffleSplit(...)</code>	Shuffle-Group(s)-Out cross-validation iterator
<code>model_selection.KFold([n_splits, shuffle, ...])</code>	K-Folds cross-validator
<code>model_selection.LeaveOneGroupOut()</code>	Leave One Group Out cross-validator
<code>model_selection.LeavePGroupsOut(n_groups)</code>	Leave P Group(s) Out cross-validator
<code>model_selection.LeaveOneOut()</code>	Leave-One-Out cross-validator
<code>model_selection.LeavePOut(p)</code>	Leave-P-Out cross-validator
<code>model_selection.PredefinedSplit(test_fold)</code>	Predefined split cross-validator
<code>model_selection.RepeatedKFold(*[, n_splits, ...])</code>	Repeated K-Fold cross validator.
<code>model_selection.RepeatedStratifiedKFold(*[, ...])</code>	Repeated Stratified K-Fold cross validator.
<code>model_selection.ShuffleSplit([n_splits, ...])</code>	Random permutation cross-validator
<code>model_selection.StratifiedKFold([n_splits, ...])</code>	Stratified K-Folds cross-validator.
<code>model_selection.StratifiedShuffleSplit(...)</code>	Stratified ShuffleSplit cross-validator
<code>model_selection.StratifiedGroupKFold(...)</code>	Stratified K-Folds iterator variant with non-overlapping groups.
<code>model_selection.TimeSeriesSplit([n_splits, ...])</code>	Time Series cross-validator

思考:

- 如何基于交叉验证，进行模型的选择？
- K-fold CV用于模型选择/评价的具体实现过程？
- K-fold CV 中的K值一般为多少？
- 何时使用LOOCV？何时使用K-fold CV？
- 如何基于交叉验证，进行模型的评价？
- 最终要使用的模型应怎么得到？



以监督式学习系统为例，首先**考察最终模型泛化能力的评估方式**
然后**再理解如何在生成最终模型之前，用交叉验证法进行模型选择。**

给定已知答案的**数据集** $D = \{(x_i, y_i), i = 1, \dots, N\}$

$\left\{ \begin{array}{l} \text{训练集 } D_{train} \text{ --模型的学习} \\ \text{测试集 } D_{test} \text{ --模型泛化能力的评价} \end{array} \right.$

$$D = D_{train} \cup D_{test}$$

数据集 D 划分的几种典型实现方式

- [1]留出法 (*hold-out*)
- [2]交叉验证 (*cross validation*)
- [3]自助法 (*bootstrapping*)

如何划分:

- “**随机打乱**”——回归
- **分层随机打乱**——分类



[1]留出法 (*hold-out*)、留出法交叉验证 (*hold - out cv*)

$$D = D_{train} \cup D_{test}$$

$$\Phi = D_{train} \cap D_{test}$$

数据集**随机划分**尽量**保持数据分布的一致性**

- A. 单独一次随机划分，估计结果不够稳定可靠
- B. 应多次随机划分，重复评估，**取结果的均值及标准差!!!**
(*hold - out cross - validation*)



D_{train} D_{test}

$$\frac{2}{3} \sim \frac{3}{4}$$

$$\frac{1}{4} \sim \frac{1}{3}$$

矛盾:

- **训练集规模应足够大**, 以便使模型的学习, 尽可能在模型学习过程中, 让其见识更为丰富的样本多样性; 但会导致测试集内样本多样性降低, 基于测试集的评价结果不够稳定、准确, 无法较好近似模型的泛化能力。
- **测试集规模应足够大**, 以便使测试误差更接近泛化误差; 但会导致训练集规模降低, 使得训练得到的模型与基于整个数据集得到的模型差别较大, 降低了评估结果的保真性。



河北师范大学软件学院
Software College of Hebei Normal University

[2] k -倍交叉验证

(k -fold cross validation, k -fold CV) – rotation estimation

$$D = D_{train} \cup D_{test} \quad \Phi = D_{train} \cap D_{test}$$

数据集的随机划分尽量**保持数据分布的一致性**

随机打乱 D , 均分成 k 等份

$k = ?$ 3, 5, 10

($k - 1$) 份

1 份



D_{train}

D_{test}

- { **单轮** k -倍交叉验证
- { **多轮** k -倍交叉验证

悲观、有偏估计

留一法交叉验证 ($leave-one-out$ cross-validation, $LOO-CV$)

无偏估计



河北师范大学软件学院
Software College of Hebei Normal University

例：基于单轮K-折交叉验证错误率，评价某分类模型的预测性能

STEP1. 将样本集D分层随机打乱，均分成互斥的K等份： $D = D_1 \cup \dots \cup D_K$

STEP2. for $j=1,2,\dots,K$, do:

以样本集 D_j 为测试集 D_{test} ，其余部分构成训练集 $D_{train}=D \setminus D_j$

以 D_{train} 学习得到模型 $model_j$ 评价 D_{test} ，得到**测试错误率** $Error_j$

STEP3. 估计上述K个错误率的均值及标准差:

$$\mu(Error) = \frac{1}{K} \sum_{j=1}^K Error_j$$

$$\sigma(Error) = \left[\frac{1}{K} \sum_{j=1}^K (Error_j - \mu(Error))^2 \right]^{\frac{1}{2}}$$

STEP4. 输出K-折交叉验证的错误率估计结果： **$\mu(Error) \pm \sigma(Error)$**

注意：对于分类问题，面向交叉验证的数据集划分应采用分层方式(即：Stratified k-fold cross validation)，确保训练集、测试集的类别分布一致。

例：Comparison between Support Vector Machines, the Kernel Fisher Discriminant (KFD), a single radial basis function classifier (RBF), AdaBoost (AB), and regularized AdaBoost (ABR) on 13 different benchmark datasets (see text). Best result in bold face, second best in italics.

平均错误率 **±** 错误率标准差

	SVM	KFD	RBF	AB	AB _R
Banana	11.5±0.07	10.8±0.05	10.8±0.06	12.3±0.07	<i>10.9±0.04</i>
B.Cancer	<i>26.0±0.47</i>	25.8±0.46	27.6±0.47	30.4±0.47	26.5±0.45
Diabetes	<i>23.5±0.17</i>	23.2±0.16	24.3±0.19	26.5±0.23	23.8±0.18
German	23.6±0.21	<i>23.7±0.22</i>	24.7±0.24	27.5±0.25	24.3±0.21
Heart	16.0±0.33	<i>16.1±0.34</i>	17.6±0.33	20.3±0.34	16.5±0.35
Image	<i>3.0±0.06</i>	3.3±0.06	3.3±0.06	2.7±0.07	2.7±0.06
Ringnorm	1.7±0.01	1.5±0.01	1.7±0.02	1.9±0.03	<i>1.6±0.01</i>
F.Sonar	32.4±0.18	<i>33.2±0.17</i>	34.4±0.20	35.7±0.18	34.2±0.22
Splice	10.9±0.07	10.5±0.06	<i>10.0±0.10</i>	10.1±0.05	9.5±0.07
Thyroid	4.8±0.22	4.2±0.21	4.5±0.21	<i>4.4±0.22</i>	4.6±0.22
Titanic	22.4±0.10	23.2±0.20	23.3±0.13	<i>22.6±0.12</i>	<i>22.6±0.12</i>
Twonorm	3.0±0.02	2.6±0.02	2.9±0.03	3.0±0.03	<i>2.7±0.02</i>
Waveform	<i>9.9±0.04</i>	<i>9.9±0.04</i>	10.7±0.11	10.8±0.06	9.8±0.08



例：基于留一法交叉验证正确率，评价某分类模型的预测性能

给定样本集 $D = \{(x_i, y_i), i = 1, \dots, N\}$

STEP1. 初始化计数器 $\text{Counter} = 0$

STEP2. for $j = 1, 2, \dots, N$, do:

以第 j 个样本 (x_j, y_j) 为测试样本，其余样本构成训练集 $D_{\text{train}} = D \setminus \{(x_j, y_j)\}$

以 D_{train} 学习得到模型 model_j 预测 x_j 的类别输出为 $\hat{y}_j$

若 $\hat{y}_j$ 与 y_j 一致，则 $\text{Counter} = \text{Counter} + 1$

STEP3. 输出留一法交叉验证的正确率：

$$\text{Acc} = \frac{\text{Counter}}{N} \times 100\%$$



留一法交叉验证的数据划分

```
import numpy as np
from sklearn.model_selection import LeaveOneOut
```

```
X = np.array([[1, 2], [3, 4], [5, 6], [7, 8]])
```

```
y = np.array([1, 2, 3, 4])
```

```
loo = LeaveOneOut()
```

```
print(loo)
```

```
print('number of splites:', loo.get_n_splits(X))
```

```
for train_index, test_index in loo.split(X):
```

```
    print("\nTRAIN:", train_index, "TEST:", test_index)
```


```
    X_train, X_test = X[train_index], X[test_index]
```

```
    y_train, y_test = y[train_index], y[test_index]
```

```
    print(X_train, y_train)
```

```
    print(X_test, y_test)
```


基于单轮K-折交叉验证的模型选择



[3]自助法 (*bootstrapping*)

bootstrap sampling

数据集 $D = \{(x_i, y_i), i = 1, \dots, N\}$ -- 初始数据集



训练集 D_{train} -- 模型的学习

方式1. 对初始数据集 D 有放回的随机抽取 N 次, 每次抽取 1 个样本
得自助数据集 D'

方式2. 从原始数据集 D 内随机抽取样本 “若干(?)”

测试集 D_{test} -- 模型泛化能力的评价


对数据集 D 中没有被抽取到的样本集 $D_{test} = D \setminus D'$

初始数据集内, 样本未被抽取的概率 $\lim_{N \rightarrow \infty} \left(1 - \frac{1}{N}\right)^N = \frac{1}{e} \approx 0.368$

自助法估计, 也称“包外估计”(out-of-bag estimation), 例: 包外错误率


自助法常用于**集成学习**(如: bagging、随机森林)时, **集成模型的性能评价**。基本过程:

- 每个版本的训练集 D_{train} 对应一个个体模型的学习
- 针对样本集D内每个样本, 当其作为某个版本训练集的包外样本时, 基于相应的个体模型, 对该**包外测试样本**的输出预测, 记录其**预测结果**及其作为**包外测试样本的次数**。
- 综合样本集D内每个样本的预测结果
例: 对于分类问题, 以投票方式决定每个样本的最终预测类
- 最终, 生成集成模型的最终评价结果




思考: 如何基于交叉验证方式, 进行模型的选择?

例: 基于给定训练集 $D_{train} = \{(x_i, y_i), i = 1, \dots, N\}$, 针对 $C=3$ 的分类问题, 采用交叉验证方式进行KNN分类模型的选择






训练集



近邻数K值不同时的分类结果

K=1


K=5




基于单轮5-fold cross validation 进行近邻数K值的优选



训练集=估计集 $\cup$ 验证集





主要内容

1. 模型的学习能力与泛化能力

2. 交叉验证

3. (基于测试集的)模型评价


3.1 基于测试集的二分类模型评价

两种情况: (1)非对称类别: 是vs.非

(2)对称类别: 第1类vs.第2类

3.2 基于测试集的多分类模型的评价

3.3 基于测试集的真实函数预测模型评价



https://scikit-learn.org/stable/modules/model_evaluation.html

Scoring Classification	Function	Comment
'accuracy'	<code>metrics.accuracy_score</code>	
'balanced_accuracy'	<code>metrics.balanced_accuracy_score</code>	
'top_k_accuracy'	<code>metrics.top_k_accuracy_score</code>	
'average_precision'	<code>metrics.average_precision_score</code>	
'neg_brier_score'	<code>metrics.brier_score_loss</code>	
'f1'	<code>metrics.f1_score</code>	for binary targets
'f1_micro'	<code>metrics.f1_score</code>	micro-averaged
'f1_macro'	<code>metrics.f1_score</code>	macro-averaged
'f1_weighted'	<code>metrics.f1_score</code>	weighted average
'f1_samples'	<code>metrics.f1_score</code>	by multilabel sample
'neg_log_loss'	<code>metrics.log_loss</code>	requires <code>predict_proba</code> support
'precision' etc.	<code>metrics.precision_score</code>	suffixes apply as with 'f1'
'recall' etc.	<code>metrics.recall_score</code>	suffixes apply as with 'f1'
'jaccard' etc.	<code>metrics.jaccard_score</code>	suffixes apply as with 'f1'
'roc_auc'	<code>metrics.roc_auc_score</code>	
'roc_auc_ovr'	<code>metrics.roc_auc_score</code>	
'roc_auc_ovo'	<code>metrics.roc_auc_score</code>	
'roc_auc_ovr_weighted'	<code>metrics.roc_auc_score</code>	
'roc_auc_ovo_weighted'	<code>metrics.roc_auc_score</code>	



河北师范大学软件学院
Software College of Hebei Normal University

<https://scikit-learn.org/stable/modules/classes.html#module-sklearn.metrics>

Classification metrics

See the [Classification metrics](#) section of the user guide for further details.

<code>metrics.accuracy_score(y_true, y_pred, *[, ...])</code>	Accuracy classification score.
<code>metrics.auc(x, y)</code>	Compute Area Under the Curve (AUC) using the trapezoidal rule.
<code>metrics.average_precision_score(y_true, ...)</code>	Compute average precision (AP) from prediction scores.
<code>metrics.balanced_accuracy_score(y_true, ...)</code>	Compute the balanced accuracy.
<code>metrics.brier_score_loss(y_true, y_prob, *)</code>	Compute the Brier score loss.
<code>metrics.classification_report(y_true, y_pred, *)</code>	Build a text report showing the main classification metrics.
<code>metrics.cohen_kappa_score(y1, y2, *[, ...])</code>	Cohen's kappa: a statistic that measures inter-annotator agreement.
<code>metrics.confusion_matrix(y_true, y_pred, *)</code>	Compute confusion matrix to evaluate the accuracy of a classification.
<code>metrics.dcg_score(y_true, y_score, *[, k, ...])</code>	Compute Discounted Cumulative Gain.
<code>metrics.det_curve(y_true, y_score[, ...])</code>	Compute error rates for different probability thresholds.
<code>metrics.f1_score(y_true, y_pred, *[, ...])</code>	Compute the F1 score, also known as balanced F-score or F-measure.
<code>metrics.fbeta_score(y_true, y_pred, *, beta)</code>	Compute the F-beta score.
<code>metrics.hamming_loss(y_true, y_pred, *[, ...])</code>	Compute the average Hamming loss.
<code>metrics.hinge_loss(y_true, pred_decision, *)</code>	Average hinge loss (non-regularized).
<code>metrics.jaccard_score(y_true, y_pred, *[, ...])</code>	Jaccard similarity coefficient score.
<code>metrics.log_loss(y_true, y_pred, *[, eps, ...])</code>	Log loss, aka logistic loss or cross-entropy loss.
<code>metrics.matthews_corrcoef(y_true, y_pred, *)</code>	Compute the Matthews correlation coefficient (MCC).



河北师范大学软件学院
Software College of Hebei Normal University

<https://scikit-learn.org/stable/modules/classes.html#module-sklearn.metrics>

<code>metrics.matthews_corrcoef(y_true, y_pred, *)</code>	Compute the Matthews correlation coefficient (MCC).
<code>metrics.multilabel_confusion_matrix(y_true, ...)</code>	Compute a confusion matrix for each class or sample.
<code>metrics.ndcg_score(y_true, y_score, *, k, ...)</code>	Compute Normalized Discounted Cumulative Gain.
<code>metrics.precision_recall_curve(y_true, ...)</code>	Compute precision-recall pairs for different probability thresholds.
<code>metrics.precision_recall_fscore_support(...)</code>	Compute precision, recall, F-measure and support for each class.
<code>metrics.precision_score(y_true, y_pred, *, ..., ...)</code>	Compute the precision.
<code>metrics.recall_score(y_true, y_pred, *, ..., ...)</code>	Compute the recall.
<code>metrics.roc_auc_score(y_true, y_score, *, ..., ...)</code>	Compute Area Under the Receiver Operating Characteristic Curve (ROC AUC) from prediction scores.
<code>metrics.roc_curve(y_true, y_score, *, ..., ...)</code>	Compute Receiver operating characteristic (ROC).
<code>metrics.top_k_accuracy_score(y_true, y_score, *)</code>	Top-k Accuracy classification score.
<code>metrics.zero_one_loss(y_true, y_pred, *, ..., ...)</code>	Zero-one classification loss.



二分类的情况之一： 非对称类别(是 vs. 非)

(人脸vs.非人脸； 垃圾邮件vs.非垃圾邮件)

- 什么是混淆矩阵？如何计算混淆矩阵？
- 如何利用混淆矩阵生成若干评价指标？
- 什么是ROC曲线？如何利用有限规模测试样本绘制ROC曲线？
- 如何基于ROC曲线进行模型的评价与比较？
- 如何计算ROC曲线下面积(即：AUC值，也称AUC ROC)？
- 什么是P-R曲线？如何利用有限规模测试样本绘制P-R曲线？
- 如何基于P-R曲线实现模型的定性或定量评价？
- 如何计算P-R曲线下面积(即：AUC_PR)？
- 哪种曲线更适合非对称类别分类模型的性能评价？为什么？



方式1.基于混淆矩阵的两类别分类模型的性能评价

方式2.基于ROC曲线/P-R曲线的性能评价

方式1.基于混淆矩阵的两类别分类模型的性能评价

混淆矩阵： confusion matrix

(1)样本的两种自然类别状态

通常设定感兴趣的一类为正类

类别标号	类别各种名称			
1	Positive (P)	正	阳性	Case Samples (病理样本)
0或-1或2	Negative (N)	负	阴性	Control Samples (对照样本)

(2)两类决策的混淆矩阵(confusion matrix)

正确分类； 错误分类； 决策阈值

自然状态 True Value Actual Value	预测输出(Predicated Outcome)	
	Positive (Predicated 1)	Negative (Predicated 0 or -1)
Positive (True 1)	a True Positive(TP) 真阳性 真正类 Hits	b False Negative(FN) 假阴性 Misses 假负类

概率形式(正确分类； 错误分类)----条件概率

自然状态 True Value Actual Value	预测输出(Predicated Outcome)	
	Positive (Predicated 1)	Negative (Predicated 0 or -1)
Positive (True 1)	Sn--灵敏度 $P(Predicated P True P)$	β--假阴性率 $P(Predicated N True P)$
Negative (True 0 或-1)	α--假阳性率 $P(Predicated P True N)$	Sp--特异度 $P(Predicated N True N)$

$P(Predicated P | True P) + P(Predicated N | True P) = 1$

$P(Predicated P | True N) + P(Predicated N | True N) = 1$

(3)基于两类别混淆矩阵的评价指标

[1](阳性类)查准率,精度(Precision,P) $Precision = \frac{TP}{TP + FP}$

[2](阳性类)查全率,召回率(Recall,R),灵敏度(Sensitivity)

命中率, 真阳性率(TruePositiveRate) $S_n = Recall = \frac{TP}{TP + FN}$

[3]特异度(Specificity),真阴性率(TrueNegativeRate) $S_p = \frac{TN}{TN + FP}$

[4]假阴性率(FalseNegativeRate),漏报率(MissedRate)
第2类错误率 $\beta = \frac{FN}{FN + TP}$

[5]假阳性率(FalsePositiveRate),虚警率(FalseAlarmRate)
第1类错误率 $\alpha = \frac{FP}{TN + FP}$



河北师范大学软件学院
Software College of Hebei Normal University

[6](阳性类的) F_β -Score以及 F_1 -Score

---Precision与Recall的调和平均

$$F_\beta = \frac{1}{\frac{1}{\beta^2 + 1} \left(\beta^2 \frac{1}{R} + 1 \frac{1}{P} \right)} = \frac{(\beta^2 + 1) P \cdot R}{\beta^2 P + R}$$

$0 < \beta < 1$,更看重P

$\beta > 1$, 更看重R

$$\beta=1 \text{ 时, } F_1 = \frac{2}{\frac{1}{R} + \frac{1}{P}} = \frac{2P \cdot R}{P + R} = \frac{2TP}{2TP + FP + FN} = \frac{2TP}{\text{测试样本总数} + TP - TN}$$

[7]马修相关系数(Matthews Correlation Coefficient,MCC)

类别不均衡的两类别分类, 公平度量模型预测能力

$$MCC = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP + FN)(TN + FP)(TP + FP)(TN + FN)}}$$







河北师范大学软件学院
Software College of Hebei Normal University

- 方式1.基于混淆矩阵的两类别分类模型的性能评价
- 方式2.基于ROC曲线/P-R曲线的性能评价

(1)ROC曲线(Receiver Operating Characteristic Curves)及绘制


The ROC curve is a graphical plot of the sensitivity, or true positive rate (y-axis), vs. false positive rate (1 – specificity or 1 – true negative rate) (x-axis), for a binary classifier system as its discrimination threshold is varied.





TP	FN
FP	TN

{ 真阳性率 $Sn(t)$
 { 假阳性率 $\alpha(t)$



决策阈值 $t \Rightarrow$

$$\text{特异度 (Specificity, 真阴性率)} \quad Sp(t) = \frac{TN(t)}{FP(t) + TN(t)}$$

$$\text{假阴性率 (第二类错误率)} \quad \beta(t) = \frac{FN(t)}{FN(t) + TP(t)}$$

$$\text{假阳性率 (第一类错误率, 误报率)} \quad \alpha(t) = 1 - Sp(t) = \frac{FP(t)}{FP(t) + TN(t)}$$

$$\text{真阳性率 (Sensitivity, 敏感度, 召回率)} \quad Sn(t) = 1 - \beta(t) = \frac{TP(t)}{FN(t) + TP(t)}$$


(2) 基于ROC曲线的分类器性能评价

第一，根据分类器的设计指标要求，由ROC曲线确定真实分类器的工作点

类条件密度已知，改变决策阈值，得ROC曲线：

ROC曲线上每个点，均对应一对(灵敏度，特异度)；

根据分类器对两种指标要求，确定曲线工作点




ROC曲线越往左上靠，ROC曲线越优，

存在一个平衡点，使这个平衡点就是 $\max(TPR - FPR)$ 所对应的分类器阈值


(2)基于ROC曲线的分类器性能评价

第二，类别数=2的分类器性能评价-AUC
AUC-ROC曲线下的面积AUC (Area Under ROC Curves)
ROC曲线越靠近坐标系的左上角,AUC值越大，分类器性能越好

$$AUC = \frac{1}{2} \sum_{i=1}^{N-1} ((\alpha_{i+1} - \alpha_i)(R_{i+1} + R_i))$$
 AUC-ROC



(a) ROC 曲线与 AUC



(b) 基于有限样例绘制的 ROC 曲线与 AUC

自然状态 True Value Actual Value	预测输出(Predicated Outcome)	
	Positive (Predicated 1)	Negative (Predicated 0 or -1)
Positive (True 1)	S_n $P(\text{Predicated } P \text{True } P)$	β $P(\text{Predicated } N \text{True } P)$
Negative (True 0 或 -1)	α $P(\text{Predicated } P \text{True } N)$	S_p $P(\text{Predicated } N \text{True } N)$

例：疾病诊断

“positive(阳性类)” --疾病

“negative(阴性类)” --正常

(1)不希望漏诊疾病

希望结果： 真阳性率=1

不希望结果： 真阴性率降低(极端值=0)

(2)不希望误判为疾病



希望结果： 真阴性率=1, 假阳性率=0

不希望结果： 真阳性率降低(极端值=0) 假阴性率升高(极端值=1)

ROC曲线靠近左上角


(2) 基于ROC曲线的分类器性能评价

- 可用于不同分类器性能比较
- 可针对同种分类器，进行特征选择、样本规模等优劣比较。




- 可以使用AUC值，单独评价每个特征的类鉴别能力
- 可以结合多个特征的多条ROC曲线横向比较各特征的类区分性

(3) P-R曲线(Precision-Recall Curve)及其AUC-PR



TP	FN
FP	TN

$$\left\{ \begin{aligned} \text{precision}(t) &= \frac{TP(t)}{TP(t) + FP(t)} \\ \text{recall}(t) &= \frac{TP(t)}{TP(t) + FN(t)} \end{aligned} \right.$$



- 定性比较：如果一个学习器的P-R曲线被另一学习器的P-R曲线完全包住，可断言后者性能优于前者。例如：A、B学习器优于学习器C。
 - 定量评价方式1：借助不同P-R曲线下方的面积值，进行横向比较
 - 定量评价方式2：结合平衡点或者F1值。
- 平衡点(BEP, break even point)是P-R曲线与直线 $P=R$ 的交点。
 $P=R$ 值越大，学习器性能较好。
- $F1 = 2 * P * R / (P + R)$ 。F1值越大，该学习器性能越好。

二分类的情况之二：
对称类别(第1类vs.第2类)

(例：猫vs.狗)


- 什么是混淆矩阵？该混淆矩阵与“非对称的二分类”混淆矩阵的区别？
- 如何产生混淆矩阵？如何基于混淆矩阵产生评价指标？
- 什么是ROC曲线？如何利用有限规模测试样本绘制ROC曲线？
- 对于对称类别的二分类问题，一个测试集可以同时得到几条ROC曲线？
- 如何结合这些ROC曲线进行分类模型的性能评价？



河北师范大学软件学院
Software College of Hebei Normal University

(1) 混淆矩阵(confusion matrix)

第1类；第2类；决策阈值



$$A = [a_{ij}]_{2 \times 2}$$

真实类别	预测类别	
	第1类	第2类
第1类	a_{11}	a_{12}
第2类	a_{21}	a_{22}

a_{ij} ----参与测试的样本中，真实类别为第*i*类，但预测为第*j*类的样本数



河北师范大学软件学院
Software College of Hebei Normal University

测试集 $D_{\text{test}} = \{(x_i, y_i), i = 1, \dots, N_{\text{test}}\}$

总体预测错误率:

$$Err_{\text{test}} = \frac{1}{N_{\text{test}}} \sum_{i=1}^{N_{\text{test}}} I(y_i \neq \hat{y}_i) \times 100\%$$

总体预测正确率:

$$Acc_{\text{test}} = \frac{1}{N_{\text{test}}} \sum_{i=1}^{N_{\text{test}}} I(y_i = \hat{y}_i) \times 100\%$$

(2) 基于两类别混淆矩阵的评价指标

[1] 总体正确率, 准确率, 准确度 (Overall Accuracy) $Accuracy = \frac{\sum_{i=1}^2 a_{ii}}{\sum_{i=1}^2 \sum_{j=1}^2 a_{ij}} \times 100\%$

[2] 总体错误率 (Error Rate) $Error = \frac{a_{12} + a_{21}}{\sum_{i=1}^2 \sum_{j=1}^2 a_{ij}} \times 100\% = 1 - Accuracy$

[3] 第*i*类查准率, 精度 (Precision, *P*) $P_i = \frac{a_{ii}}{\sum_{j=1}^2 a_{ji}} \quad i = 1, 2$

[4] 第*i*类查全率, 召回率 (Recall, *R*), 正确率 $R_i = \frac{a_{ii}}{\sum_{j=1}^2 a_{ij}} = Acc_i \quad i = 1, 2$

[5]第*i*类 F_β - Score 以及 F_1 - Score -- P_i 与 R_i 的调和平均

$$F_\beta^{(i)} = \frac{(\beta^2 + 1)P_i \cdot R_i}{\beta^2 P_i + R_i} \quad i = 1, 2$$

$0 < \beta < 1$, 更看重 P_i

$\beta > 1$, 更看重 R_i

$$\beta = 1 \text{ 时, } F_1^{(i)} = \frac{2P_i \cdot R_i}{P_i + R_i}$$

[6] 宏查准率、宏查全率 $Macro_P = \frac{1}{2} \sum_{i=1}^2 P_i$ $Macro_R = \frac{1}{2} \sum_{i=1}^2 R_i$

[7] $C=2$ 个类别的 宏平均 F_1 - Score (Macro-averaging F_1)

$$Macro_F_1 = \frac{2 \times Macro_P \times Macro_R}{Macro_P + Macro_R}$$



[8] 各类预测正确率的几何平均——类别不均衡的评价

$$Acc_{G-mean} = \left(\prod_{i=1}^2 Acc_i \right)^{\frac{1}{2}}$$

[9] 马修相关系数


(Matthews Correlation Coefficient, MCC)

类别不均衡的两类别分类，公平度量模型预测能力

$$MCC = \frac{a_{11} \cdot a_{22} - a_{12} \cdot a_{21}}{\sqrt{(a_{11} + a_{12})(a_{21} + a_{22})(a_{11} + a_{21})(a_{12} + a_{22})}}$$



主要内容



1. 模型的学习能力与泛化能力

2. 交叉验证

3. (基于测试集的)模型评价

3.1 基于测试集的二分类模型评价

3.2 基于测试集的多分类模型的评价

3.3 基于测试集的实值函数预测模型评价



多类别分类($C > 2$)

- 如何结合测试集的分类标签信息以及预测标签，产生多类别分类的混淆矩阵？
- 如何结合 C 阶混淆矩阵，产生若干评价指标？
- 一个 C 阶混淆矩阵可生成 C 个“第 i 类vs.非第 i 类”二阶混淆矩阵
- 一个测试集可以同时得到几条ROC曲线？
- 如何结合这些ROC曲线进行分类模型的性能评价？



(1) 混淆矩阵(confusion matrix)

C阶矩阵: $A = [a_{ij}]_{C \times C}$

a_{ij} ----测试样本集内，真实类别为第*i*类，但预测为第*j*类的样本数

真实类别为第*i*类的样本总数: $\sum_{j=1}^C a_{ij}$

预测类别为第*j*类的样本总数: $\sum_{i=1}^C a_{ij}$



测试样本总数: $\sum_{i=1}^C \sum_{j=1}^C a_{ij}$

例：基于混淆矩阵的手写体数字识别

混淆矩阵为10行*10列

	class <i>j</i> predicted by a classifier									
true class <i>i</i>	'0'	'1'	'2'	'3'	'4'	'5'	'6'	'7'	'8'	'9'
'0'	97	0	0	0	0	0	1	0	0	1
'1'	0	98	0	0	1	0	0	1	0	0
'2'	0	0	96	1	0	1	0	1	0	0
'3'	0	0	2	95	0	1	0	0	1	0
'4'	0	0	0	0	98	0	0	0	0	2
'5'	0	0	0	1	0	97	0	0	0	0
'6'	1	0	0	0	0	1	98	0	0	0
'7'	0	0	1	0	0	0	0	98	0	0
'8'	0	0	0	1	0	0	1	0	96	1
'9'	1	0	0	0	3	1	0	0	0	95

sklearn.metrics.ConfusionMatrixDisplay



河北师范大学软件学院
Software College of Hebei Normal University

测试集 $D_{\text{test}} = \{(x_i, y_i), i = 1, \dots, N_{\text{test}}\}$

总体预测错误率:

$$Err_{\text{test}} = \frac{1}{N_{\text{test}}} \sum_{i=1}^{N_{\text{test}}} I(y_i \neq \hat{y}_i) \times 100\%$$

总体预测正确率:

$$Acc_{\text{test}} = \frac{1}{N_{\text{test}}} \sum_{i=1}^{N_{\text{test}}} I(y_i = \hat{y}_i) \times 100\%$$



河北师范大学软件学院
Software College of Hebei Normal University

(2) 基于多类别混淆矩阵的评价指标

[1] 总体正确率, 准确率, 准确度 (Overall Accuracy) $Accuracy = \frac{\sum_{i=1}^C a_{ii}}{\sum_{i=1}^C \sum_{j=1}^C a_{ij}} \times 100\%$

[2] 总体错误率 (Error Rate) $Error = 1 - Accuracy$

[3] 第*i*类查准率, 精度 (Precision, P_i) $P_i = \frac{a_{ii}}{\sum_{j=1}^C a_{ji}} \quad i = 1, \dots, C$

[4] 第*i*类查全率, 召回率 (Recall, R_i), 正确率 $R_i = \frac{a_{ii}}{\sum_{j=1}^C a_{ij}} = Acc_i \quad i = 1, \dots, C$

[5] 宏查准率、宏查全率 $Macro_P = \frac{1}{C} \sum_{i=1}^C P_i \quad Macro_R = \frac{1}{C} \sum_{i=1}^C R_i$

[6] 第*i*类 F_β -Score 以及 F_1 -Score -- P_i 与 R_i 的调和平均

$$F_\beta^{(i)} = \frac{(\beta^2 + 1) P_i \cdot R_i}{\beta^2 P_i + R_i} \quad i = 1, \dots, C$$

$0 < \beta < 1$, 更看重 P_i

$\beta > 1$, 更看重 R_i

$$\beta = 1 \text{ 时, } F_1^{(i)} = \frac{2 P_i \cdot R_i}{P_i + R_i}$$

[7] C 个类别的宏平均 F_1 -Score (Macro-averaging F_1)

$$Macro_F_1 = \frac{2 \times Macro_P \times Macro_R}{Macro_P + Macro_R}$$

[8]由C阶混淆矩阵，得到C个"第*i*类*vs.* 非第*i*类"混淆矩阵
将这C个混淆矩阵取平均，得到平均混淆矩阵

微查准 率/微 精度(Precision) $micro_P = \frac{\overline{TP}}{\overline{TP} + \overline{FP}}$

微查全 率/微 召回率(Recall) $micro_R = \frac{\overline{TP}}{\overline{TP} + \overline{FN}}$

微*F*₁ - Score $micro_F_1 = \frac{2micro_P \cdot micro_R}{micro_P + micro_R}$



[9] *Kappa*系数 (Cohen's kappa)
Cohen's kappa measures the agreement between two raters who each classify *N* items into *C* mutually exclusive categories.

$$K = \frac{p_0 - p_e}{1 - p_e} = \frac{\frac{\sum_{i=1}^C a_{ii}}{\sum_{i=1}^C \sum_{j=1}^C a_{ij}} - \frac{\sum_{i=1}^C \left[\frac{\sum_{j=1}^C a_{ij}}{C} \cdot \frac{\sum_{k=1}^C a_{ki}}{C} \right]}{\left(\frac{\sum_{i=1}^C \sum_{j=1}^C a_{ij}}{C} \right)^2}}{1 - \frac{\sum_{i=1}^C \left[\frac{\sum_{j=1}^C a_{ij}}{C} \cdot \frac{\sum_{k=1}^C a_{ki}}{C} \right]}{\left(\frac{\sum_{i=1}^C \sum_{j=1}^C a_{ij}}{C} \right)^2}} \quad -1 \leq K \leq 1$$

考虑两个极端：
没有错分；完全错分

理想情况，完全一致，*K* = 1;
*K*值越小，越不一致，甚至为负.

- 基于kappa系数一致性的不同等级
- [0,0.20) 极低一致性(slight)
 - [0.20,0.40) 一般一致性(fair)
 - [0.40~0.60) 中等的一致性(moderate)
 - [0.6~0.80) 高度的一致性(substantial)
 - [0.8~1] 几乎完全一致(almost perfect)

关于 p_0, p_e 的具体说明:

(1) p_0 --实际一致率(总体预测正确率)
$$p_0 = \frac{\sum_{i=1}^C a_{ii}}{\sum_{i=1}^C \sum_{j=1}^C a_{ij}}$$

(2) $\begin{cases} p_e \text{--理论一致率(机遇一致性)} \\ 1-p_e \text{--非机遇一致性} \end{cases}$

p_e 表示一个样本被抽取的类别与决策类别一致的**概率**

第*i*类样本被观测到的概率

样本决策为第*i*类的概率

$$p_e = \sum_{i=1}^C p_{ei} = \frac{\sum_{i=1}^C \left[\frac{\sum_{j=1}^C a_{ij} \sum_{k=1}^C a_{ki}}{\left(\sum_{i=1}^C \sum_{j=1}^C a_{ij} \right)^2} \right]}{\sum_{i=1}^C 1} = \sum_{i=1}^C \left(\frac{\sum_{j=1}^C a_{ij}}{\sum_{i=1}^C \sum_{j=1}^C a_{ij}} \cdot \frac{\sum_{k=1}^C a_{ki}}{\sum_{i=1}^C \sum_{j=1}^C a_{ij}} \right)$$

被抽取的类别与决策类别一致的概率

观测样本为第*i*类并同时被决策为第*i*类的概率

主要内容

1. 模型的学习能力与泛化能力

2. 交叉验证


3. (基于测试集的)模型评价


3.1 基于测试集的二分类模型评价

3.2 基于测试集的多分类模型的评价

3.3 基于测试集の実值函数预测模型评价

说明: 聚类模型的评价在后续聚类模型学习中给出。





Regression metrics

See the [Regression metrics](#) section of the user guide for further details.

<code>metrics.explained_variance_score(y_true, ...)</code>	Explained variance regression score function.
<code>metrics.max_error(y_true, y_pred)</code>	The max_error metric calculates the maximum residual error.
<code>metrics.mean_absolute_error(y_true, y_pred, *)</code>	Mean absolute error regression loss.
<code>metrics.mean_squared_error(y_true, y_pred, *)</code>	Mean squared error regression loss.
<code>metrics.mean_squared_log_error(y_true, y_pred, *)</code>	Mean squared logarithmic error regression loss.
<code>metrics.median_absolute_error(y_true, y_pred, *)</code>	Median absolute error regression loss.
<code>metrics.mean_absolute_percentage_error(...)</code>	Mean absolute percentage error (MAPE) regression loss.
<code>metrics.r2_score(y_true, y_pred, *, ...)</code>	R^2 (coefficient of determination) regression score function.
<code>metrics.mean_poisson_deviance(y_true, y_pred, *)</code>	Mean Poisson deviance regression loss.
<code>metrics.mean_gamma_deviance(y_true, y_pred, *)</code>	Mean Gamma deviance regression loss.
<code>metrics.mean_tweedie_deviance(y_true, y_pred, *)</code>	Mean Tweedie deviance regression loss.
<code>metrics.d2_tweedie_score(y_true, y_pred, *)</code>	D ² regression score function, percentage of Tweedie deviance explained.
<code>metrics.mean_pinball_loss(y_true, y_pred, *)</code>	Pinball loss for quantile regression.

测试样本集 $D_{Test} = \{(x_i, y_i), i = 1, \dots, N\}$


1. 均方误差 (Mean Squared Error, MSE)

`sklearn.metrics.mean_squared_error`

$$MSE(y, \hat{y}) = \frac{1}{N} \sum_{i=1}^N [y_i - \hat{y}_i]^2$$

2. 均方根误差 (Root Mean Squared Error, RMSE)

$$RMSE(y, \hat{y}) = \sqrt{\frac{1}{N} \sum_{i=1}^N [y_i - \hat{y}_i]^2} = \sqrt{MSE}$$



3. 平均绝对误差 (Mean Absolute Error, MAE)

`sklearn.metrics.mean_absolute_error`

$$MAE(\mathbf{y}, \hat{\mathbf{y}}) = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|$$

4. 中值绝对误差 (Median Absolute Error)

最大绝对误差 (Max Absolute Error)

`sklearn.metrics.median_absolute_error`


`sklearn.metrics.max_error`

$$Median_AE(\mathbf{y}, \hat{\mathbf{y}}) = \text{median}_{i \in \{1, \dots, N\}} \{|y_i - \hat{y}_i|\}$$

$$Max_AE(\mathbf{y}, \hat{\mathbf{y}}) = \max_{i \in \{1, \dots, N\}} \{|y_i - \hat{y}_i|\}$$



河北师范大学软件学院
Software College of Hebei Normal University



5. 均方根对数误差 (Root Mean Squared Logarithmic Error, RMSLE)

`sklearn.metrics.mean_squared_log_error`

$$\begin{aligned} RMSLE(\mathbf{y}, \hat{\mathbf{y}}) &= \sqrt{\frac{1}{N} \sum_{i=1}^N [\log(y_i + 1) - \log(\hat{y}_i + 1)]^2} \\ &= \sqrt{\frac{1}{N} \sum_{i=1}^N \left[\log \frac{1 + y_i}{1 + \hat{y}_i} \right]^2} \end{aligned}$$

该评价指标的应用前提:

- 样本的“标签值”为重尾分布 (Heavy-tailed distribution)
此时, 先进行对数运算再取RMSE, 可有效避免模型评价时, 少数极大值的影响。
- 此外, 应确保标签值与预测值为非负。



河北师范大学软件学院
Software College of Hebei Normal University

6. 平均绝对百分比误差 (Mean Absolute Percentage Error, MAPE)

`sklearn.metrics.mean_absolute_percentage_error`

$$MAPE(y, \hat{y}) = 100\% \times \frac{1}{N} \sum_{i=1}^N \frac{|y_i - \hat{y}_i|}{\max\{\epsilon, |y_i|\}}$$

为避免被0除，引入小正数


该指标的取值范围 $[0, +\infty)$

- 若 $MAPE = 0$ ，则预测模型为完美模型；
- 若 $MAPE > 100\%$ ，则预测模型为劣质模型。

注意：当真值存在取值0情况时，出现分母0除问题，上述评价指标将不可用。

7. 对称平均绝对百分比误差

(Symmetric Mean Absolute Percentage Error, SMAPE)



$$SMAPE(y, \hat{y}) = 100\% \times \frac{1}{N} \sum_{i=1}^N 2 \left| \frac{y_i - \hat{y}_i}{|y_i| + |\hat{y}_i|} \right|$$

该指标的取值范围 $[0, +\infty)$

- 若 $SMAPE = 0$ ，则预测模型为完美模型；
- 若 $SMAPE > 100\%$ ，则预测模型为劣质模型。

注意：当真值及预测值同为0时，出现分母0除问题，上述评价指标将不可用。

8. 决定系数

(可决系数 *coefficient of determination*: R^2)

[*sklearn.metrics.r2_score*](#)


$$R^2(y, \hat{y}) = 1 - \frac{MSE(y, \hat{y})}{Var(y)} = 1 - \frac{\frac{1}{N} \sum_{i=1}^N [y_i - \hat{y}_i]^2}{\frac{1}{N} \sum_{i=1}^N [y_i - \bar{y}]^2}$$
$$= 1 - \frac{SSE}{SST} = 1 - \frac{\sum_{i=1}^N [y_i - \hat{y}_i]^2}{\sum_{i=1}^N [y_i - \bar{y}]^2}$$

决定系数取值在 $(-\infty, 1]$ 之间:

- 越接近于1, 说明模型的预测效果越好;
- 越接近于0, 说明模型的预测效果越差;
- 若取值为负值, 说明模型的效果非常差。



河北师范大学软件学院
Software College of Hebei Normal University



9. 解释方差 (Explained Variance)

[*sklearn.metrics.explained_variance_score*](#)


$$\text{explained_variance_score}(y, \hat{y}) = 1 - \frac{Var(y - \hat{y})}{Var(y)}$$

解释方差取值在 $(-\infty, 1]$ 之间:


- 越接近于1, 说明模型的预测效果越好;
- 越小于1, 说明模型的预测效果越差。



河北师范大学软件学院
Software College of Hebei Normal University



本章思考题(1)




1. 什么是模型的学习能力？泛化能力？
2. 区分：训练集、测试集、估计集、验证集。
3. 结合分类与回归问题，给定已知答案的样本集，如何基于K-fold CV或LOOCV进行模型的评价？**如何得到最终的模型？** K值一般多大？
4. 给定已知答案的训练样本集，请结合分类与回归问题，如何基于K-fold CV或LOOCV进行模型的选择？K值一般多大？
5. 区分hold out, bootstrapping, K-fold CV与LOOCV的使用场合。



河北师范大学软件学院
Software College of Hebei Normal University

本章思考题(2)




1. 对于**两类别(非对称类别/对称类别)**、**多类别**的分类问题，如何分类模型对测试集的预测结果，得到相应的混淆矩阵？**上述情况下的混淆矩阵有什么区别？**如何计算混淆矩阵？如何以图的方式可视化混淆矩阵？
2. 如何针对**上述三种情况**，利用混淆矩阵生成若干评价指标？
3. 什么是ROC曲线？如何利用有限规模测试样本绘制ROC曲线？
如何基于ROC曲线进行模型的评价与比较？
如何计算ROC曲线下面积(即：AUC值，也称AUC_ROC)？
4. 什么是P-R曲线？如何利用有限规模测试样本绘制P-R曲线？
如何基于P-R曲线实现模型的定性或定量评价？
如何计算P-R曲线下面积(即：AUC_PR)？
5. 哪种曲线更适合非对称类别分类模型的性能评价？为什么？



河北师范大学软件学院
Software College of Hebei Normal University

本章思考题(3)



1. 理解并掌握回归模型的常用评价指标：

- 决定系数、方差解释比
- 平均绝对误差、最大绝对误差、中值绝对误差
- 平均平方误差、均方根误差
- 均方根对数误差及应用场合
- 平均绝对百分比误差、对称平均绝对百分比误差
- ...

薛乐仁



河北师范大学软件学院
Software College of Hebei Normal University