

智能软件开发方向基础



第5章 决策树 Decision Tree

第1部分 理解认识决策树
张朝晖

2023~2024学年第二学期

序号	内容
1	概述
2	机器学习的基本概念
3	模型的选择与性能评价
4	数据的获取、探索与准备
5	近邻模型-----分类、回归
6	决策树模型-----分类、回归
7	集成学习-----分类、回归
8	(朴素)贝叶斯模型-----分类
9	聚类
10	特征降维及低维可视化(PCA, t-SNE)
11	总复习

本课件主要内容及有关例子，主要参考了

1. 周志华，《机器学习》
2. 李航，《统计学习方法》

特此感谢！

思考题

1. 什么是决策树？
决策树模型的叶子节点与特征空间、训练样本集存在什么对应关系？
2. 如何利用到达决策树某节点处的训练集度量该节点的不纯度？
(三种典型的节点不纯度度量方式)
3. ID3, C4.5, CART 三种典型决策树的算法实现步骤？
4. 三种决策树模型中，非叶子节点所用的特征是采用何种规则进行选择？给出具体的选择方式。
以根节点处特征选择为例，描述原理。
5. 哪种决策树模型还可用于实值函数回归？若用于回归，如何生成预测结果？
6. 给定一棵初步构建的决策树，如何对其进行剪枝？

主要内容

决策树

基于树形结构的决策模型—决策树

包括：决策树构建方法；决策树的剪枝；决策树的使用

1 度量型与非度量型特征(metric/nonmetric features)

- 2 初步认识决策树
3. 决策树的构建
4. 过学习与决策树的剪枝

样本的特征描述

(1) 度量型特征 (metric features)

—数值型特征(numeric features)

(2) 非度量型特征(nonmetric features)

如：名义特征/标称数据(nominal features)

序数特征(ordinal features)

区间特征(interval features)

非度量型特征描述的样本分类，处理方式：

方式1

非度量型特征 $\xrightarrow{\text{编码}}$ 度量型特征 $\xrightarrow{\text{基于度量型特征的样本分类}}$ 分类结果

编码可能会 { 造成信息损失
引入人为信息

方式2

基于非度量型特征的样本直接分类

决策树可直接面向非度量型、度量型特征描述的样本。

主要内容

决策树

基于树形结构的决策模型——决策树

包括：决策树构建方法；决策树的剪枝；决策树的使用


1 度量/非度量特征(metric/nonmetric features)

2 初步认识决策树


3.决策树的构建

4.过学习与决策树的剪枝

(1)什么是决策树?




决策树是关于if-then规则的集合
规则互斥、完备




例：CART回归树

- 特征空间
- 训练集
- 输入样本
- 各节点信息
- 非叶节点
- 叶节点



例：CART分类树

- 特征空间
- 训练集
- 输入样本
- 各节点信息
- 非叶节点
- 叶节点



决策树是一种以倒立树形结构描述的决策规则集合。

由一个根节点、若干内部节点、若干叶节点组成。


每个非叶节点代表关于输入样本的一个特征测试(查询)，该节点的每个分支表示测试的一个结果；每个叶节点代表关于输入样本的一个决策结果。

- 若为分类树，则决策结果为预测类别(或关于所有类别的预测概率)；
- 若为回归树，则决策结果为预测的实数值。

从根节点通向叶节点的一条路径对应一条决策规则。
决策树是应用最广的归纳推理方法之一，模型直观。

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

西瓜数据集2.0




西瓜数据集3.0a

编号	密度	含糖率	好瓜
1	0.697	0.460	是
2	0.774	0.376	是
3	0.634	0.264	是
4	0.608	0.318	是
5	0.556	0.215	是
6	0.403	0.237	是
7	0.481	0.149	是
8	0.437	0.211	是
9	0.666	0.091	否
10	0.243	0.267	否
11	0.245	0.057	否
12	0.343	0.099	否
13	0.639	0.161	否
14	0.657	0.198	否
15	0.360	0.370	否
16	0.593	0.042	否
17	0.719	0.103	否

CART分类树

- 连续特征空间
- 类别数=2
- 二叉树



(2) 决策树的优点


- 语义可表示性

---从根节点到叶节点的一条决策规则为**合取式**
 ---利用**合取式**和**析取式**获得某个类别的明确描述

- 决策速度快

只需一系列关于待决策样本的简单查询，即可对该样本的输出做出判断

- 可以很自然的嵌入专家的先验知识



(4) 决策树模型的学习与使用

- 模型的监督式学习—决策树的**(初步)构建(与剪枝)**

归纳：决策规则的生成。

基于一定数量训练样本，学习**决策规则**，自动构造。

训练样本集的划分 → 特征空间的最终划分

- 模型的使用—利用生成的规则，对观测样本进行决策推理

A. 模型的学习

- 决策树构建中的节点特征选择
利用到达当前节点的训练样本集，从中选择最优划分特征
- 决策树的生成(模型的局部选择)
递归生成决策树，拟合训练样本
- 决策树的剪枝(模型的全局选择)

简化模型，使其泛化能力更好
许多分枝反映的是训练样本中的噪声和孤立点

为避免过学习，应控制树的规模，检测和剪枝
预剪枝(prepruning)、后剪枝(postpruning)

B. 模型的使用

从根节点开始，对输入样本的特征取值提问

与根节点相连的不同分枝，对应于特征的不同取值

根据不同回答，转向相应的分枝

在新到达的节点处，做类似的分枝判断...

持续上述过程直到叶子节点，输出该叶子节点对应的类别标记(或函数值)。

