

智能软件开发方向基础

第7章 朴素贝叶斯分类

PART3-最大似然估计与朴素贝叶斯模型的实现流程

张朝晖

河北师范大学

2024.03~06



朴素贝叶斯分类模型

特征之间强独立
(类条件独立)
Strong Independence

+

贝叶斯公式



关键问题:

1. 什么是朴素贝叶斯分类模型?
2. 如何利用已知类别标签的训练集学习朴素贝叶斯模型?
3. 朴素贝叶斯模型的实现过程?



➤ 如何基于朴素贝叶斯模型解决实际分类问题?

基本思路:

- [1] 利用有限规模训练样本, 估计
$$\begin{cases} \text{先验概率} & P(\omega_i) \\ \text{条件概率密度} & p(x|\omega_i) \text{ 或 } P(x|\omega_i) \end{cases} \quad i=1,2,\dots,c$$
- [2] 利用估计结果, 设计贝叶斯分类器
对未知样本 x 进行判决

上述过程又称基于样本的两步(朴素)贝叶斯决策。



问题: 如何估计有关概率/概率密度函数?



主要内容

第1. 问题引入

什么是朴素贝叶斯分类模型?

第2. 概率密度函数的估计

第3. 朴素贝叶斯分类模型的具体实现流程



主要内容

第1. 问题引入

第2. 概率密度函数的估计

第3. 朴素贝叶斯分类模型的具体实现流程



➤ 如何进行有关概率/概率密度函数的估计?

前提 { 训练样本数量足够多
训练样本分布能代表样本的真实分布. 如: i.i.d

A. 状态先验概率 $P(\omega_i)$, $i=1,2,\dots,c$ 的估计

比较容易 { **依靠经验**
如: 异常细胞识别, 医生可根据
以往细胞病理检查统计结果,
做出推断
利用训练数据中各类出现的频度估计

1.最大似然估计的问题描述

假设条件

- [1] **参数 θ** : 确定的未知量 (θ 不是随机变量)
- [2] **c类** { c个确定类别的样本集 $\mathcal{X}_i, i=1,\dots,c$.
各样本集的样本个数 $N_i, i=1,\dots,c$
- [3] **独立同分布**(i.i.d: independent identical distribution)
样本集 $\mathcal{X}_i$ 中, 各样本依 $p(x|\omega_i)$ 独立抽取, $i=1,\dots,c$
- [4] **类条件概率密度 $p(x|\omega_i)$** , $i=1,\dots,c$ { 函数形式确定
参数 θ_i 未知
 $p(x|\omega_i)$ 依赖于 θ_i , 记: $p(x|\omega_i; \theta_i)$, 或 $p(x; \theta_i)$
- [5] **各类样本只含本类的分布信息**
各参数 θ_i 在函数上相互独立, θ_i 的估计不受 $\mathcal{X}_j (j \neq i)$ 影响。

⇒ **目标** 根据各类训练样本集 $\mathcal{X}_1, \dots, \mathcal{X}_c$, 分别估计各类密度函数
参数(向量) $\theta_1, \dots, \theta_c$ 的“最可能”的取值

B. (类条件)概率密度函数估计基本方法

[1] 参数估计 (parametric estimation)

类条件总体概率密度函数

形式已知 根据对问题一般认识,
假设随机变量 x 服从某种分布
参数未知 利用训练样本估计分布参数

两种类型 { **监督参数估计**(supervised parametric estimation)
各训练样本类别状态已知
非监督参数估计(unsupervised parametric estimation)
各训练样本类别状态未知

[2] 非参数估计 (nonparametric estimation)

概率密度函数形式未知;
利用训练样本, 直接推断概率密度函数

2.最大似然估计的基本思想

c个独立问题, 各问题均可表述为

已知:

某类训练样本集 $\mathcal{X} = \{x_1, \dots, x_N\}$;

各样本按已知整体分布形式 $p(x; \theta)$ 独立抽取(i.i.d);

参数向量 $\theta = [\theta_1, \dots, \theta_s]^T$

目标:

采用最大似然法, 估计该类密度函数的参数 θ .

主要内容

第1. 问题引入

第2. 概率密度函数的估计

参数估计法之一——最大似然估计

(Maximum Likelihood Estimation, MLE)

--以正态分布的概率密度函数估计为例

第3. 朴素贝叶斯分类模型的具体实现流程

2.最大似然估计的基本思想(续1)

(1) 似然函数(likelihood function)

$$l(\theta) = p(\mathcal{X}; \theta) = p(x_1, \dots, x_N; \theta) = \prod_{i=1}^N p(x_i; \theta)$$

参数 θ 下, 样本集 $\mathcal{X} = \{x_1, \dots, x_N\}$ 的观测似然值

或: 参数 θ 下, N 个独立样本 $x_1, \dots, x_N$ 的联合似然值。

样本集 $\mathcal{X}$ 固定时, $l(\theta)$ 随 θ 的取值而变, 是 θ 的函数。

⇒ $l(\theta)$ 体现了参数 θ 下取得样本集 $\mathcal{X}$ 的可能性

给定样本集 $\mathcal{X}$ 前提下, $l(\theta)$ 是关于 θ 的函数

2.最大似然估计的基本思想(续2)

(2)对数似然函数

$$H(\theta) = \ln l(\theta) = \ln p(\mathcal{X}; \theta) = \sum_{i=1}^N \ln p(x_i; \theta)$$

(3)最大似然估计量

$$\text{若 } \theta^* = \arg \max_{\theta \in \Theta} [l(\theta)] = \arg \max_{\theta \in \Theta} [\ln l(\theta)]$$

则 θ^* 是 θ 的最大似然估计量。

最大似然估计的实质:

根据抽取的 N 个样本 $x_1, \dots, x_N$, 估计它们

"最可能"来自哪一个密度函数。

例1. 单变量正态分布概率密度函数的最大似然估计

适合的应用场景:

(1)一维特征空间, 某个类别的“正态分布的类条件概率密度函数”估计

(2)多维特征空间, 某个类别中某个特征的“正态分布边缘密度函数”估计

3.似然函数连续的必要条件

记 梯度算子 $\nabla_{\theta} = \left[\frac{\partial}{\partial \theta_1} \quad \dots \quad \frac{\partial}{\partial \theta_s} \right]^T$

若 似然函数 $l(\theta)$, $H(\theta)$ 关于 θ 连续可微, 则 $\nabla_{\theta} H(\theta) = 0$

$$\begin{aligned} \nabla_{\theta} H(\theta) &= \begin{bmatrix} \frac{\partial H(\theta)}{\partial \theta_1} \\ \vdots \\ \frac{\partial H(\theta)}{\partial \theta_s} \end{bmatrix} = \begin{bmatrix} \sum_{k=1}^N \frac{\partial}{\partial \theta_1} [\ln p(x_k; \theta)] \\ \vdots \\ \sum_{k=1}^N \frac{\partial}{\partial \theta_s} [\ln p(x_k; \theta)] \end{bmatrix} \\ &= \sum_{k=1}^N \begin{bmatrix} \frac{\partial}{\partial \theta_1} [\ln p(x_k; \theta)] \\ \vdots \\ \frac{\partial}{\partial \theta_s} [\ln p(x_k; \theta)] \end{bmatrix} = \sum_{k=1}^N \nabla_{\theta} [\ln p(x_k; \theta)] \end{aligned}$$

单变量正态分布概率密度函数 $p(x; \theta)$

$$p(x; \theta) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(x-\mu)^2}{2\sigma^2} \right] = \frac{1}{\sqrt{2\pi\theta_2}} \exp \left[-\frac{(x-\theta_1)^2}{2\theta_2} \right]$$

待估计参数 $\theta = [\theta_1, \theta_2]^T = [\mu, \sigma^2]^T$

样本集 $\mathcal{X} = \{x_1, \dots, x_N\}$ 各样本独立抽取 (i.i.d)

似然函数

$$l(\theta) = p(\mathcal{X}; \theta) = \prod_{i=1}^N p(x_i; \theta) = \frac{1}{(2\pi\theta_2)^{\frac{N}{2}}} \exp \left[-\frac{\sum_{i=1}^N (x_i - \theta_1)^2}{2\theta_2} \right]$$

$$\text{对数似然函数 } H(\theta) = \ln l(\theta) = -\frac{\sum_{i=1}^N (x_i - \theta_1)^2}{2\theta_2} - \frac{N}{2} \ln(2\pi\theta_2)$$

最大似然估计量 θ^* 必满足

$$\nabla_{\theta} H(\theta) = \sum_{k=1}^N \nabla_{\theta} [\ln p(x_k; \theta)] = 0$$

$$\text{即 } \begin{cases} \sum_{k=1}^N \frac{\partial}{\partial \theta_1} [\ln p(x_k; \theta)] = 0 \\ \vdots \\ \sum_{k=1}^N \frac{\partial}{\partial \theta_s} [\ln p(x_k; \theta)] = 0 \end{cases}$$

若上述方程组的某个解 θ^* 能使 $H(\theta)$ 最大, 则 θ^* 为 θ 的最大似然估计。

- 精确解例: 解方程组
- 数值解例: 梯度下降法

$$\text{由于 } H(\theta) = \ln l(\theta) = -\frac{\sum_{i=1}^N (x_i - \theta_1)^2}{2\theta_2} - \frac{N}{2} \ln(2\pi\theta_2)$$

$$\text{所以 } \nabla_{\theta} H(\theta) = \begin{bmatrix} \frac{\partial}{\partial \theta_1} H(\theta) \\ \frac{\partial}{\partial \theta_2} H(\theta) \end{bmatrix} = \begin{bmatrix} \frac{1}{\theta_2} \sum_{i=1}^N (x_i - \theta_1) \\ -\frac{N}{2\theta_2} + \frac{\sum_{i=1}^N (x_i - \theta_1)^2}{2\theta_2^2} \end{bmatrix}$$

最大似然估计量 θ^* 满足方程: $\nabla_{\theta} H(\theta) = 0$

$$\text{即 } \begin{cases} \frac{1}{\theta_2} \sum_{i=1}^N (x_i - \theta_1) = 0 \\ -\frac{N}{2\theta_2} + \frac{\sum_{i=1}^N (x_i - \theta_1)^2}{2\theta_2^2} = 0 \end{cases} \quad \text{解得 } \begin{cases} \mu^* = \theta_1^* = \frac{1}{N} \sum_{i=1}^N x_i \\ (\sigma^2)^* = \theta_2^* = \frac{1}{N} \sum_{i=1}^N (x_i - \mu^*)^2 \end{cases}$$

样本集 $\mathcal{X} = \{x_1, \dots, x_N\}$ 各样本依 $p(x; \theta)$ 独立抽取

$$\begin{cases} \text{样本均值} & \bar{x} = \frac{1}{N} \sum_{i=1}^N x_i \\ \text{样本方差} & s^2 = \frac{1}{N-1} \sum_{i=1}^N (x_i - \bar{x})^2 \end{cases}$$

参数 μ 、 σ^2 的最大似然估计

$$\begin{cases} \mu^* = \frac{1}{N} \sum_{i=1}^N x_i = \bar{x} \\ (\sigma^2)^* = \frac{1}{N} \sum_{i=1}^N (x_i - \mu^*)^2 \end{cases}$$

样本集 $\mathcal{X} = \{x_1, \dots, x_N\}$ 各样本依 $p(x | \theta)$ 独立抽取

$$\begin{cases} \text{样本均值} & \bar{x} = \frac{1}{N} \sum_{k=1}^N x_k \\ \text{样本协方差矩阵} & C = \frac{1}{N-1} \sum_{k=1}^N (x_k - \bar{x})(x_k - \bar{x})^T \end{cases}$$

最大似然参数估计

$$\begin{cases} \text{期望} & \mu^* = \frac{1}{N} \sum_{i=1}^N x_i = \bar{x} \\ \text{协方差矩阵} & \Sigma^* = \frac{1}{N} \sum_{i=1}^N (x_i - \mu^*)(x_i - \mu^*)^T \end{cases}$$

例2. 多元正态分布概率密度函数的最大似然估计

适合场景:

某个类别的“正态分布形式的类条件概率密度函数估计”

(1) 一般情况(非朴素情况)

(2) 各特征“强独立”

例2. 多元正态分布概率密度函数的最大似然估计

适合场景:

某个类别的“正态分布类条件概率密度函数估计”

(1) 一般情况

(2) 各特征“强独立”(朴素贝叶斯)

对于多变量正态分布 μ, Σ 均未知

概率密度函数

$$p(x; \theta) = p(x; \mu, \Sigma) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp \left[-\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right]$$

d 维特征空间

样本集 $\mathcal{X} = \{x_1, \dots, x_N\}$ $x_i = [x_i^{(1)}, \dots, x_i^{(d)}]^T, i = 1, \dots, N$

$$\text{待估计的参数 } \theta = \begin{cases} \text{均值向量} & \mu = [\mu^{(1)}, \mu^{(2)}, \dots, \mu^{(d)}]^T \\ \text{协方差矩阵} & \Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \dots & \sigma_{1d} \\ \sigma_{21} & \sigma_{22} & \dots & \sigma_{2d} \\ \dots & \dots & \dots & \dots \\ \sigma_{d1} & \sigma_{d2} & \dots & \sigma_{dd} \end{bmatrix} \end{cases}$$

其中: $\sigma_{ij} = \sigma_{ji}$

对于多变量正态分布 μ, Σ 均未知

$$\Sigma = \begin{bmatrix} \sigma_{11} & & & \\ & \sigma_{22} & & \\ & & \dots & \\ & & & \sigma_{dd} \end{bmatrix} = \begin{bmatrix} (\sigma^{(1)})^2 & & & \\ & (\sigma^{(2)})^2 & & \\ & & \dots & \\ & & & (\sigma^{(d)})^2 \end{bmatrix}$$

概率密度函数

$$p_X(x; \theta) = p_X(x; \mu, \Sigma) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp \left[-\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right]$$

$$= \prod_{i=1}^d \frac{1}{\sqrt{2\pi} \sigma^{(i)}} \exp \left[-\frac{1}{2} \left(\frac{x^{(i)} - \mu^{(i)}}{\sigma^{(i)}} \right)^2 \right] = \prod_{i=1}^d p_{X^{(i)}}(x^{(i)}; \mu^{(i)}, \sigma^{(i)2})$$

$$p_{X^{(i)}}(x^{(i)}; \mu^{(i)}, \sigma^{(i)2}) = \frac{1}{\sqrt{2\pi} \sigma^{(i)}} \exp \left[-\frac{1}{2} \left(\frac{x^{(i)} - \mu^{(i)}}{\sigma^{(i)}} \right)^2 \right]$$

随机变量 $X^{(i)}$ 的边缘密度

$$p_{X^{(i)}}(x^{(i)}; \mu^{(i)}, \sigma^{(i)2}) = \frac{1}{\sqrt{2\pi}\sigma^{(i)}} \exp\left[-\frac{1}{2}\left(\frac{x^{(i)} - \mu^{(i)}}{\sigma^{(i)}}\right)^2\right]$$

随机向量 X 的概率密度函数: $p_X(x; \mu, \Sigma) = \prod_{i=1}^d p_{X^{(i)}}(x^{(i)}; \mu^{(i)}, \sigma^{(i)2})$

边缘密度 $p_{X^{(i)}}(x^{(i)}; \mu^{(i)}, \sigma^{(i)2})$ 最大似然参数估计

$$\begin{cases} \text{期望} & (\mu^{(i)})^* = \frac{1}{N} \sum_{k=1}^N x_k^{(i)} \\ \text{方差} & (\sigma^{(i)2})^* = \frac{1}{N} \sum_{k=1}^N (x_k^{(i)} - (\mu^{(i)})^*)^2 \end{cases}$$
$$\Rightarrow \begin{cases} \text{期望向量} & \mu^* = [(\mu^{(1)})^*, (\mu^{(2)})^*, \dots, (\mu^{(d)})^*]^T \\ \text{协方差矩阵} & \Sigma^* = \text{diag}((\sigma^{(1)2})^*, (\sigma^{(2)2})^*, \dots, (\sigma^{(d)2})^*) \end{cases}$$

若观测样本 x 所在**特征空间为连续的**:

$$P(\omega_j | x) = \frac{P^*(\omega_j) \mathbf{P}^*(x | \omega_j)}{\mathbf{P}^*(x)} = \frac{P^*(\omega_j) \mathbf{P}^*(x | \omega_j)}{\sum_{i=1}^c P^*(\omega_i) \mathbf{P}^*(x | \omega_i)}$$
$$j = 1, 2, \dots, c$$

若观测样本 x 所在**特征空间为离散的**:

$$P(\omega_j | x) = \frac{P^*(\omega_j) \mathbf{P}^*(x | \omega_j)}{\mathbf{P}^*(x)} = \frac{P^*(\omega_j) \mathbf{P}^*(x | \omega_j)}{\sum_{i=1}^c P^*(\omega_i) \mathbf{P}^*(x | \omega_i)}$$
$$j = 1, 2, \dots, c$$

第1. 问题引入

第2. 概率密度函数的估计

第3. 朴素贝叶斯分类模型的具体实现流程

情况1. 连续特征空间

情况2. 离散特征空间

情况3. 混合特征空间(思考)

朴素贝叶斯法, 基于**贝叶斯公式**、以及**各特征条件独立的假设**, 实现贝叶斯决策。

连续特征空间: $p(x | \omega_j) = \prod_{k=1}^d p(x^{(k)} | \omega_j)$

离散特征空间: $P(x | \omega_j) = \prod_{k=1}^d P(x^{(k)} | \omega_j)$

基于样本的两步贝叶斯决策

[1] 利用**有限规模训练样本** $\{(x_j, y_j), j=1, \dots, N\}$,

设计贝叶斯分类器. 估计

$$\begin{cases} \text{先验概率} & P(\omega_i) \\ \text{条件概率密度} & p(x | \omega_i) \text{ 或 } \text{条件概率} P(x | \omega_i) \end{cases}$$
$$i=1, 2, \dots, c$$

[2] 利用估计的**结果**, 对**未知样本 x** 进行判决

主要内容

第1. 问题引入

第2. 概率密度函数的估计

第3. 朴素贝叶斯分类模型的具体实现流程

情况1. 连续特征空间

情况2. 离散特征空间

情况3. 混合特征空间(思考)

例：高斯朴素贝叶斯 GaussianNB

https://scikit-learn.org/stable/modules/generated/sklearn.naive_bayes.GaussianNB.html

连续特征空间的 最小错误率朴素贝叶斯(Naive Bayes) 分类 — 算法描述

例：鸢尾花的贝叶斯分类？



ω_i 类：随机变量 $\mathbf{x}^{(k)}$ 的**条件**边缘密度

$$p_{X^{(k)}}(x^{(k)} | \omega_i; \mu^{(k)}, \sigma^{(k)2}) = \frac{1}{\sqrt{2\pi}\sigma^{(k)}} \exp\left[-\frac{1}{2}\left(\frac{x^{(k)} - \mu^{(k)}}{\sigma^{(k)}}\right)^2\right]$$

随机向量 $\mathbf{x}$ 的概率密度函数： $p_X(\mathbf{x} | \omega_i; \mu, \Sigma) = \prod_{k=1}^d p_{X^{(k)}}(x^{(k)} | \omega_i; \mu^{(k)}, \sigma^{(k)2})$

条件边缘密度 $p_{X^{(k)}}(x^{(k)} | \omega_i; \mu^{(k)}, \sigma^{(k)2})$ 最大似然参数估计

$$\begin{cases} \text{期望} & (\mu^{(k)})^* = \frac{1}{N} \sum_{j=1}^N x_j^{(k)} \\ \text{方差} & (\sigma^{(k)2})^* = \frac{1}{N} \sum_{j=1}^N (x_j^{(k)} - (\mu^{(k)})^*)^2 \end{cases} \quad k=1, \dots, d$$
$$\Rightarrow \begin{cases} \text{期望向量} & \mu^* = [(\mu^{(1)})^*, (\mu^{(2)})^*, \dots, (\mu^{(d)})^*]^T \\ \text{协方差矩阵} & \Sigma^* = \text{diag}((\sigma^{(1)2})^*, (\sigma^{(2)2})^*, \dots, (\sigma^{(d)2})^*) \end{cases}$$



输入：

(1) 训练样本集 $\{(\mathbf{x}_j, y_j), j=1, \dots, N\}$,

其中 $\mathbf{x}_j = [x_j^{(1)}, \dots, x_j^{(d)}]^T$

$x_j^{(k)}$ 是第 j 个样本的第 k 个特征；

$k \in \{1, 2, \dots, d\}$, $y_j \in \{\omega_1, \omega_2, \dots, \omega_C\}$

(2) 待决策的观测样本 $\mathbf{x} = [x^{(1)}, \dots, x^{(d)}]^T$

输出：观测样本 $\mathbf{x}$ 的类别



(2) 对于给定的观测样本 $\mathbf{x} = [x^{(1)}, \dots, x^{(d)}]^T$ ，计算

$$P^*(\omega = \omega_j) p^*(X = \mathbf{x} | \omega = \omega_j)$$

$$= P^*(\omega = \omega_j) \prod_{k=1}^d P^*(X^{(k)} = x^{(k)} | \omega = \omega_j)$$

其中： $j \in \{1, 2, \dots, C\}$

(3) 预测观测样本 $\mathbf{x}$ 的类别 y

$$y^* = \arg \max_{\omega_j, j \in \{1, 2, \dots, C\}} [P^*(\omega = \omega_j) p^*(X = \mathbf{x} | \omega = \omega_j)]$$



实现步骤：

(1) 利用训练样本集估计**先验概率**及**条件概率密度函数**

$$\text{估计先验概率: } P^*(\omega = \omega_i) = \frac{\sum_{j=1}^N I(y_j = \omega_i)}{N}, \quad i \in \{1, 2, \dots, C\}$$

$$\text{估计条件密度: } p^*(X = \mathbf{x} | \omega = \omega_i) = \prod_{k=1}^d p^*(X^{(k)} = x^{(k)} | \omega = \omega_i)$$

分别利用训练样本集内第 ω_i 类所有样本的第 k 个特征取值

$$\text{估计类条件边缘密度值: } p^*(X^{(k)} = x^{(k)} | \omega = \omega_i)$$

特征序号 $k \in \{1, 2, \dots, d\}$

类别序号 $i \in \{1, 2, \dots, C\}$

$$\mathbf{X} = [X^{(1)}, \dots, X^{(d)}]^T$$



主要内容

第1. 问题引入

第2. 概率密度函数的估计

第3. 朴素贝叶斯分类模型的具体实现流程

情况1. 连续特征空间

情况2. 离散特征空间

情况3. 混合特征空间(思考)



离散特征空间的 最小错误率的朴素贝叶斯(Naive Bayes) 分类 ——算法描述



河北师范大学软件学院
Software College of Hebei Normal University

离散特征空间的 最小错误率的朴素贝叶斯(Naive Bayes) 分类 ——算法描述



河北师范大学软件学院
Software College of Hebei Normal University

离散特征空间的 最小错误率的朴素贝叶斯(Naive Bayes) 分类 ——算法描述



河北师范大学软件学院
Software College of Hebei Normal University

离散特征空间的 最小错误率的朴素贝叶斯(Naive Bayes) 分类 ——算法描述



河北师范大学软件学院
Software College of Hebei Normal University

离散特征空间的 最小错误率的朴素贝叶斯(Naive Bayes) 分类 ——算法描述



河北师范大学软件学院
Software College of Hebei Normal University

离散特征空间的 最小错误率的朴素贝叶斯(Naive Bayes) 分类 ——算法描述



河北师范大学软件学院
Software College of Hebei Normal University

解：首先进行先验概率、以及各类条件概率分布列的估计

方式2：
LAPLACE平滑

$$P(Y=1)=\frac{10}{17}, \quad P(Y=-1)=\frac{7}{17}$$

$$P(X^{(1)}=1|Y=1)=\frac{3}{12}, \quad P(X^{(1)}=2|Y=1)=\frac{4}{12}, \quad P(X^{(1)}=3|Y=1)=\frac{5}{12}$$

$$P(X^{(2)}=S|Y=1)=\frac{2}{12}, \quad P(X^{(2)}=M|Y=1)=\frac{5}{12}, \quad P(X^{(2)}=L|Y=1)=\frac{5}{12}$$

$$P(X^{(1)}=1|Y=-1)=\frac{4}{9}, \quad P(X^{(1)}=2|Y=-1)=\frac{3}{9}, \quad P(X^{(1)}=3|Y=-1)=\frac{2}{9}$$

$$P(X^{(2)}=S|Y=-1)=\frac{4}{9}, \quad P(X^{(2)}=M|Y=-1)=\frac{3}{9}, \quad P(X^{(2)}=L|Y=-1)=\frac{2}{9}$$

基于上述概率信息，对观测样本 x 进行类别决策：

对于给定的 $x=(2,S)^T$ 计算：

$$P(Y=1)P(X^{(1)}=2|Y=1)P(X^{(2)}=S|Y=1)=\frac{10}{17} \cdot \frac{4}{12} \cdot \frac{2}{12} = \frac{5}{153} = 0.0327$$

$$P(Y=-1)P(X^{(1)}=2|Y=-1)P(X^{(2)}=S|Y=-1)=\frac{7}{17} \cdot \frac{3}{9} \cdot \frac{4}{9} = \frac{28}{459} = 0.0610$$

由于 $P(Y=-1)P(X^{(1)}=2|Y=-1)P(X^{(2)}=S|Y=-1)$ 最大，所以 $y=-1$ 。

思考题

试由表的训练数据学习一个朴素贝叶斯分类器并确定 $x=(2,S)^T$ 类标记 y 。

表中 $X^{(1)}, X^{(2)}$ 为特征，取值的集合分别为 $A_1=\{1,2,3\}$, $A_2=\{S,M,L\}$ ；

Y 为类标记， $Y \in C=\{1,-1\}$

	1	2	3	4	5	6	7	8
$X^{(1)}$	1	1	1	1	1	2	2	2
$X^{(2)}$	S	M	M	S	S	S	M	M
Y	-1	-1	1	1	-1	-1	-1	1

若以表中的前8、9个样本构成训练集，如何对两个样本进行类别预测？ $(1,L)$

例：利用训练样本集估计先验概率及条件概率

估计方式--贝叶斯估计法($\lambda=1$, 称LAPLACE平滑)

$$P^*(Y=1)=\frac{\lambda + \sum_{j=1}^N I(y_j=1)}{C\lambda + N} = \frac{1 + \sum_{j=1}^8 I(y_j=1)}{2\lambda + 8} = \frac{1+3}{2+8} = \frac{4}{10}$$

$$P^*(Y=-1)=\frac{\lambda + \sum_{j=1}^N I(y_j=-1)}{C\lambda + N} = \frac{1+5}{2+8} = \frac{6}{10} = 1 - P^*(Y=1)$$

$$P^*(X^{(k)}=a_{kl}|Y=1)=\frac{\lambda + \sum_{j=1}^8 I(x_j^{(k)}=a_{kl}, y_j=1)}{S_k\lambda + \sum_{j=1}^8 I(y_j=1)}$$

引入平滑项，
以避免当估计结果
为0时，对后
验概率计算、以
及决策带来的不
良后果。