

大数据与人工智能 方向基础



第七章 朴素贝叶斯分类 Naive Bayes Classifier PART1--模型

张朝晖

2023~2024学年第二学期



序号	内容
1	概述
2	机器学习的基本概念
3	模型的选择与性能评价
4	数据的获取、探索与准备
5	近邻模型-----分类、回归
6	决策树模型-----分类、回归
7	集成学习-----分类、回归
8	(朴素)贝叶斯模型-----分类
9	聚类
10	特征降维及低维可视化(PCA, t-SNE)
11	总复习

本课概要

两种典型的(朴素)贝叶斯分类模型

- (1)最小错误率贝叶斯分类
- (2)最小风险贝叶斯分类

模型的学习 -- 概率密度函数与概率估计
朴素贝叶斯实现流程



主要内容

1. 引言
2. 贝叶斯决策模型
 - 2.1 最小错误率贝叶斯决策
连续情况；离散情况
 - 2.2 最小风险的贝叶斯决策
连续情况；离散情况
3. 正态分布的概率密度函数
4. 概率/概率密度函数估计
5. 朴素贝叶斯(Naive Bayes)分类实现流程



几个基本概念

[1]特征空间(输入空间)及特征维数

d 维特征空间,记为 $\mathfrak{R} = R^d$

[2]特征向量(随机向量) $X = [X_1, \dots, X_d]^T$

其中 $X_1, X_2, \dots, X_d$ 分别为随机变量。

$\forall x = [x_1, \dots, x_d]^T \in R^d$ 或: 观察样本 x 为 d 维

[3]状态空间(输出空间) $\{\omega_1, \dots, \omega_c\}$

类别状态数 c , 类别状态变量 ω (随机变量) $\omega \in \{\omega_1, \dots, \omega_c\}$

[4](状态)先验概率

预先已知的, 或可估计的分类系统位于某一类别的概率。

一般的 c 类问题: 各类别 ω_i 的先验概率 $P_{\omega}(\omega_i), i = 1, \dots, c$

$$P_{\omega}(\omega_1) + \dots + P_{\omega}(\omega_c) = 1$$



[5]样本分布密度(或: 总体概率密度) $p_X(x)$

$$\int_{\mathfrak{R}} p_X(x) dx = 1$$

[6]类条件概率密度函数

(class - conditional probability density function)

系统位于某种类别条件下, 模式样本 x 的概率密度分布。
同一类别对象的各属性具有一定变化范围, 以函数形式表示, 记为: $p_{X|\omega}(x | \omega_i), i = 1, \dots, c$

$$\int_{\mathfrak{R}} p_{X|\omega}(x | \omega_i) dx = 1, \quad i = 1, \dots, c$$

[7]后验概率 (posterior probability)

给定某具体模式样本的观测 x , 该样本属于某类别的概率。

记为: $P_{\omega|X}(\omega_i | x), i = 1, \dots, c$

$$\sum_{i=1}^c P_{\omega|X}(\omega_i | x) = 1$$



连续情况下，贝叶斯决策条件：

[1] 类别数目 c 一定，类别状态 $\omega_i, i=1, \dots, c$

[2] 给定：

$$\begin{cases} \text{类先验概率} & P_{\omega}(\omega_i), i=1, \dots, c \\ \text{类条件概率密度} & P_{X|\omega}(x|\omega_i), i=1, \dots, c \\ \text{损失代价} & \lambda_{ij} \end{cases}$$

(对真实状态为 ω_j 类的向量 x 采取决策 α_i 所带来的损失)

特殊情况 0-1代价 $\lambda_{ij} = \begin{cases} 0 & i=j \\ 1 & i \neq j \end{cases}$

问题：如何最为合理地对观测向量 $x = [x_1, x_2, \dots, x_d]^T \in R^d$ 进行判决？



两种典型决策模型

为方便描述，贝叶斯模型描述作如下简化：

$$\begin{aligned} p_X(x) &\Rightarrow p(x) \\ P_X(x) &\Rightarrow P(x) \end{aligned}$$

$$\begin{aligned} P_{X|\omega}(x|\omega_i) &\Rightarrow p(x|\omega_i) \\ P_{X|\omega}(x|\omega_i) &\Rightarrow P(x|\omega_i) \end{aligned}$$

$$\begin{aligned} P_{\omega|X}(\omega_i|x) &\Rightarrow P(\omega_i|x) \\ P_{\omega}(\omega_i) &\Rightarrow P(\omega_i) \end{aligned}$$



河北师范大学软件学院
Software College of Hebei Normal University

主要内容

1. 引言

2. 贝叶斯决策模型

2.1 最小错误率贝叶斯决策

连续情况；离散情况

2.2 最小风险的贝叶斯决策

连续情况；离散情况

3. 正态分布的概率密度函数

4. 概率/概率密度函数估计

5. 朴素贝叶斯(Naive Bayes)分类实现流程



河北师范大学软件学院
Software College of Hebei Normal University

分析一个两类问题----正常/异常的识别问题

→ 预测某具体观测 x 的类别状态。

给定：

(1) 两类的分类问题： $c=2$

类别状态集合 $\{w1=正常, w2=异常\}$

(2) 关于该问题，需要借助的一些信息，几种可能：

方式1. 仅仅依靠先验知识： $P(w=w_1), P(w=w_2)$

方式2. 先验知识、该细胞的具体观测 x

方式3. 先验知识、观测 x 、不同决策所带来的损失



如何决策？

1. 仅依靠先验知识(未使用关于该样本 x 的具体观测信息)

判决规则 若 $P(\omega_1) > P(\omega_2)$ ，则决策为 $x \in \omega_1$ ；反之， $x \in \omega_2$

$$P(\omega_1)=0.9 \quad P(\omega_2)=0.1$$

→ 所有待识别细胞全部决策为 $\omega_1=正常细胞$ 。

→ 决策错误率： $P(error)=1-P(\omega_1)=P(\omega_2)$

产生原因：状态先验概率提供的分类信息太少。

$P(\omega_1)$ 、 $P(\omega_2)$ 不等时，仅利用先验概率，只能把未知样本都归于某一类，无法达到正确分类的目的。

因此，先验概率不能作为判决的唯一依据。



河北师范大学软件学院
Software College of Hebei Normal University

2. “先验知识”+“证据(即：该观测样本 x)”


贝叶斯公式的实质：通过观测样本 x (证据)，将状态先验概率 $P(\omega_j)$ 转化为状态后验概率 $P(\omega_j|x)$

$$\begin{aligned} \text{posterior} &= \frac{\text{likelihood} \times \text{prior}}{\text{evidence}} & \sum_{i=1}^c P(\omega_j|x) &= 1 \\ \text{观测空间为连续特征空间} & & & \\ P(\omega_j|x) &= \frac{p(x, \omega_j)}{p(x)} = \frac{p(x|\omega_j)P(\omega_j)}{p(x)} = \frac{p(x|\omega_j)P(\omega_j)}{\sum_{i=1}^c p(x|\omega_i)P(\omega_i)} \\ \text{观测空间为离散特征空间} & & & \\ P(\omega_j|x) &= \frac{P(x, \omega_j)}{P(x)} = \frac{P(x|\omega_j)P(\omega_j)}{P(x)} = \frac{P(x|\omega_j)P(\omega_j)}{\sum_{i=1}^c P(x|\omega_i)P(\omega_i)} \end{aligned}$$



河北师范大学软件学院
Software College of Hebei Normal University

例：一维连续特征情况下，某两类问题的状态后验概率



似然函数：其它条件相等情况下，对应较大取值 $p(x|\omega_j)$ 的 ω_j 更有可能为 x 的真实类别。因此，称 $p(x|\omega_j)$ 为 ω_j 关于 x 的似然函数。

(1) 连续特征空间，两类分类问题：决策规则

对于观测样本 x ，计算 $P(\omega_j | x)$ ：

$$P(\omega_j | x) = \frac{p(x | \omega_j)P(\omega_j)}{p(x)} = \frac{p(x | \omega_j)P(\omega_j)}{\sum_{i=1}^2 p(x | \omega_i)P(\omega_i)} \quad j=1,2$$

决策规则 $\begin{cases} \text{若 } P(\omega_1 | x) > P(\omega_2 | x), \text{ 则决策为 } x \in \omega_1 \\ \text{若 } P(\omega_2 | x) > P(\omega_1 | x), \text{ 则决策为 } x \in \omega_2 \end{cases}$

上述决策对应的**错误概率** $P(e|x)$ ：

$$P(e|x) = \begin{cases} 1 - P(\omega_1 | x) = P(\omega_2 | x) < P(\omega_1 | x) & \text{若决策 } x \in \omega_1 \\ 1 - P(\omega_2 | x) = P(\omega_1 | x) < P(\omega_2 | x) & \text{若决策 } x \in \omega_2 \end{cases}$$

$$= 1 - \max \{P(\omega_1 | x), P(\omega_2 | x)\} = \min \{P(\omega_1 | x), P(\omega_2 | x)\}$$

基于**最大后验概率**的决策 $\Leftrightarrow$ 基于**最小条件错误概率** $P(e|x)$ 的决策

(2) 多类问题情况下，基于最小错误率的贝叶斯决策

后验概率

$$P(\omega_j | x) = \frac{p(x | \omega_j)P(\omega_j)}{p(x)} = \frac{p(x | \omega_j)P(\omega_j)}{\sum_{i=1}^c p(x | \omega_i)P(\omega_i)} \quad j=1,2,\dots,c$$

样本 x 的错分概率


$$P(e|x) = 1 - \max_{j=1,2,\dots,c} P(\omega_j | x)$$

基于最小错误率的决策规则：

$$\text{若 } P(\omega_i | x) = \max_{j=1,2,\dots,c} P(\omega_j | x) \quad \text{则 } x \in \omega_i$$

或

$$\text{若 } p(x | \omega_i)P(\omega_i) = \max_{j=1,2,\dots,c} p(x | \omega_j)P(\omega_j) \quad \text{则 } x \in \omega_i$$



连续特征空间，错误率(平均错误率)

错误率(平均错误率)是错误概率 $P(e|x)$ 的期望，记为 $P(e)$

对于连续随机变量 x ，有

$$P(e) = \int_{\mathcal{X}} P(e|x)p(x)dx \quad P(e|x) \geq 0, p(x) \geq 0$$

$$\text{依据: } E[f(X)] = \int_{\mathcal{X}} f(x)p_X(x)dx$$

最大后验概率贝叶斯决策就是基于最小错误率贝叶斯决策

每个 x 的判决，都对应一个条件错分概率 $P(e|x)$ ，

对于所有 x ，若能保证决策时关于 x 的后验概率最大，则可保证 $P(e|x)$ 最小，则有 $P(e)$ 最小。

贝叶斯错误率----- $P(e)$ 最小值

例：离散特征空间基于最小错误率的贝叶斯决策——例题分析

例1：为了对某种疾病进行诊断，对一批人进行一次普查，对每个人各打试验针，观察反应，然后进行统计，规律如下：

- (1) 这一批人中，每1000个人中有5个关于该疾病的病人；
- (2) 这一批人中，每100个正常人中有一个试验呈阳性反应；
- (3) 这一批人中，每100个病人中有95人试验呈阳性反应。

问：若某人(甲)呈阳性反应，甲是否正常？

分析：类别状态空间 $\Omega = \{\omega_1 = \text{正常}, \omega_2 = \text{异常}\}$

- (1) $\Rightarrow$ 先验概率
- (2) $\Rightarrow$ 类条件概率 $P(x = \text{阳性} | \omega_1)$
- (3) $\Rightarrow$ 类条件概率 $P(x = \text{阳性} | \omega_2)$

确定 $P(\omega_i | x = \text{阳性}), i=1,2$

解：观测 $x = \text{阳性}$ 。

(1) 类别状态 ω 有两种： $\omega = \omega_1$ 正常； $\omega = \omega_2$ 某病患者

(2) 根据已知条件，计算关于类别状态的后验概率。

由条件1，状态先验概率： $P(\omega_1) = 0.995, P(\omega_2) = 0.005$

由条件2,3，类条件概率： $\begin{cases} P(x = \text{阳性} | \omega_1) = 0.01 \\ P(x = \text{阳性} | \omega_2) = 0.95 \end{cases}$

(3) 决策过程：

$$P(\omega_1 | x = \text{阳性}) = \frac{P(\omega_1)P(x = \text{阳性} | \omega_1)}{P(x = \text{阳性})}$$

$$= \frac{P(\omega_1)P(x = \text{阳性} | \omega_1)}{P(\omega_1)P(x = \text{阳性} | \omega_1) + P(\omega_2)P(x = \text{阳性} | \omega_2)} = \frac{0.995 \times 0.01}{0.995 \times 0.01 + 0.005 \times 0.95} = 0.677$$

$$P(\omega_2 | x = \text{阳性}) = 1 - 0.677 = 0.323$$

$P(\omega_1 | x = \text{阳性}) > P(\omega_2 | x = \text{阳性})$

由最小错误率决策规则，将“阳性反应的甲”判决为 ω_1 (正常人)，

判决错误率：0.323

由于 $P(\omega_1) > P(\omega_2)$ ，判决时，先验概率起了明显的作用。

最小错误率贝叶斯决策—小结

两类情况下，基于最小错误率的判决规则，各等价形式：

- 1, 状态后验概率 $\begin{cases} P(\omega_1 | x) > P(\omega_2 | x), \text{则 } x \in \omega_1 \text{ 类} \\ P(\omega_1 | x) < P(\omega_2 | x), \text{则 } x \in \omega_2 \text{ 类} \end{cases}$
- 2, 似然值×先验概率 $\begin{cases} P(\omega_1)p(x|\omega_1) > P(\omega_2)p(x|\omega_2), \text{则 } x \in \omega_1 \text{ 类} \\ P(\omega_1)p(x|\omega_1) < P(\omega_2)p(x|\omega_2), \text{则 } x \in \omega_2 \text{ 类} \end{cases}$

最小错误率贝叶斯决策—小结

多类情况下，基于最小错误率的判决规则，各等价形式

(1)后验概率：

$$\text{若 } P(\omega_i | x) = \max_{j=1,2,\dots,c} P(\omega_j | x)$$

则 $x \in \omega_i$ 类

(2)似然值×先验概率：

$$\text{若 } p(x|\omega_i)P(\omega_i) = \max_{j=1,2,\dots,c} p(x|\omega_j)P(\omega_j)$$

则 $x \in \omega_i$ 类

主要内容

1. 引言

2. 贝叶斯决策模型

2.1 最小错误率贝叶斯决策

连续情况；离散情况

2.2 最小风险的贝叶斯决策

连续情况；离散情况

“先验知识” + “证据观测 x ” + “不同决策所带来的损失

3. 正态分布的概率密度函数

4. 概率/概率密度函数估计

5. 朴素贝叶斯(Naive Bayes)分类实现流程

最小错误率的贝叶斯决策，仅仅考虑判决错误。

实际决策过程中，不同类别的错误决策，还存在不同程度的损失或风险。

例：疾病的诊断

正常诊断为疾病，带来精神负担，但可进一步检查；
疾病诊断为正常，延误治疗、危及生命，损失严重。

因此，决策时可考虑不同类别的决策错误所引起的风险（损失）。

最小风险贝叶斯决策

1.问题描述

[1] 观测 x

x 为 d 维随机向量， $x = [x_1, x_2, \dots, x_d]^T$

$x_1, x_2, \dots, x_d$ 分别为随机变量。

[2] 状态空间 Ω

c 个自然状态（ c 类）， $\Omega = \{\omega_1, \dots, \omega_c\}$

[3] 决策空间(或：行动空间) $\mathcal{A}$

对观测 x 可能采取的 k 个决策 $\mathcal{A} = \{\alpha_1, \dots, \alpha_k\}$

注： c 与 k 可能不同

[4] 损失函数 $\lambda(\alpha_i, \omega_j)$

对真实类别状态为 ω_j 的观察 x ，采取决策 α_i

所带来的损失(或：风险)，简称 λ_{ij}

$i = 1, 2, \dots, k \quad j = 1, 2, \dots, c$

以“决策表格”形式提供 λ_{ij}

[5] 特征空间连续--类条件概率密度 $p(x|\omega_i)$

$$\int_{\mathcal{X}} p(x|\omega_i) dx = 1, \quad i = 1, \dots, c$$

特征空间离散--类条件概率 $P(x|\omega_i)$

$$\sum_{x \in \mathcal{X}} P(x|\omega_i) = 1, \quad i = 1, \dots, c$$

[6] 状态先验概率 $P(\omega_i)$ $\sum_{i=1}^c P(\omega_i) = 1 \quad i = 1, \dots, c$

⇒目标：对所有的 x 进行决策，使损失最小。

2.与“风险”“损失”有关的几个名词


[1]决策表(损失函数)

对于具体观测 x , 所有可能采取的决策或行动都会带来一定风险, 以决策表表示:

决策	自然状态					
	(ω_1)	(ω_2)	***	(ω_j)	***	(ω_k)
α_1	$\lambda(\alpha_1, \omega_1)$	$\lambda(\alpha_1, \omega_2)$	***	$\lambda(\alpha_1, \omega_j)$	***	$\lambda(\alpha_1, \omega_k)$
α_2	$\lambda(\alpha_2, \omega_1)$	$\lambda(\alpha_2, \omega_2)$	***	$\lambda(\alpha_2, \omega_j)$	***	$\lambda(\alpha_2, \omega_k)$
$\vdots$	损失函数 $\lambda(\alpha_i, \omega_j) = \lambda_{ij}$					$\vdots$
α_i	$\lambda(\alpha_i, \omega_1)$	$\lambda(\alpha_i, \omega_2)$	***	$\lambda(\alpha_i, \omega_j)$	***	$\lambda(\alpha_i, \omega_k)$
$\vdots$	$\vdots$	$\vdots$	***	$\vdots$	$\vdots$	$\vdots$
α_k	$\lambda(\alpha_k, \omega_1)$	$\lambda(\alpha_k, \omega_2)$	***	$\lambda(\alpha_k, \omega_j)$	***	$\lambda(\alpha_k, \omega_k)$

[2]观测 x 的条件期望损失(或: x 的条件风险) $R(\alpha|x)$

分析:



⇒ 条件期望损失: $R(\alpha|x)$

对观测 x 在各种可能类别下, 采取某具体决策 α 所造成的平均损失。

$$R(\alpha|x) = E[f(\omega)|x] = \sum_{j=1}^c f(\omega=\omega_j)P(\omega=\omega_j|x)$$



[2]观测 x 的条件期望损失(或: x 的条件风险) $R(\alpha|x)$

$$R(\alpha|x) = E[f(\omega)|x] = E[\lambda(\alpha, \omega)|x]$$

$$= \sum_{j=1}^c f(\omega=\omega_j)P(\omega=\omega_j|x)$$

$$= \sum_{j=1}^c \lambda(\alpha, \omega=\omega_j)P(\omega=\omega_j|x) = \sum_{j=1}^c \lambda(\alpha, \omega_j)P(\omega_j|x)$$

当 $\alpha = \alpha_i$ 时,

$$R(\alpha_i|x) = \sum_{j=1}^c \lambda(\alpha_i, \omega=\omega_j)P(\omega=\omega_j|x) \quad i=1,2,\dots,k$$

⇒ 对于观测 x , 可选择行为 α_i , 使 $R(\alpha_i|x) = \min_{j=1,2,\dots,k} R(\alpha_j|x)$



[3]期望风险(平均风险) $R(\alpha)$

$R(\alpha)$ 是条件期望风险 $R(\alpha(x)|x)$ 关于观测 x 的数学期望。

$$R(\alpha) = \int R(\alpha(x)|x)p(x)dx$$

意义: 对特征空间的所有 x , 采取相应决策 $\alpha(x)$ 所带来的平均风险。

⇒ 对于每个 x , 若能选择与之对应的 $\alpha(x)$, 使条件风险 $R(\alpha(x)|x)$ 最小, 则能保证期望风险 $R = R(\alpha)$ 最小

[4]贝叶斯风险: 最小的期望风险 $R^* = \min_{\alpha} R(\alpha)$



3.最小风险贝叶斯决策规则

若 对于 x , $R(\alpha_j|x) = \min_{i=1,2,\dots,k} R(\alpha_i|x)$
则 应对 x 采取行为 $\alpha = \alpha_j$



4.最小风险贝叶斯决策的计算步骤

对于观测 x

(1) 计算后验概率:

$$P(\omega_j|x) = \frac{P(\omega_j)p(x|\omega_j)}{p(x)} = \frac{P(\omega_j)p(x|\omega_j)}{\sum_{i=1}^c P(\omega_i)p(x|\omega_i)}$$

$$j=1,2,\dots,c$$

(2) 计算 x 的条件风险: $R(\alpha_i|x) = \sum_{j=1}^c \lambda(\alpha_i, \omega_j)P(\omega_j|x)$

$$i=1,2,\dots,k$$

(3) 决策: 选择关于 x 的条件风险最小的决策 α , 即
 $\alpha = \arg \min_{i=1,2,\dots,k} R(\alpha_i|x)$



5.最小风险贝叶斯决策举例--两类问题

例2：在例1的异常诊断问题中，所有化验结果对应两种判决。试验人为两类；并且，由于决策会产生不同程度风险。对应决策表如下。

决策 α_i $i = 1, 2$	自然状态 ω_j $j = 1, 2$	
	$\omega_1 = \text{正常}$	$\omega_2 = \text{异常}$
$\alpha_1 = \text{判决为 } \omega_1$	$\lambda(\alpha_1, \omega_1) = 0.5$	$\lambda(\alpha_1, \omega_2) = 6$
$\alpha_2 = \text{判决为 } \omega_2$	$\lambda(\alpha_2, \omega_1) = 2$	$\lambda(\alpha_2, \omega_2) = 0.5$

为了对疾病进行诊断，对一批人进行一次普查，对每个人各打试验针，观察反应，然后进行统计，规律如下：

- (1) 这一批人中，每1000个人中有5个病人；
- (2) 这一批人中，每100个正常人中有一个试验呈阳性反应；
- (3) 这一批人中，每100个病人中有95人试验呈阳性反应。

问：若某人（甲）呈阳性反应，甲是否正病？



分析：

状态空间 $\Omega = \{\omega_1 = \text{正常}, \omega_2 = \text{异常}\}$

决策空间 $\mathcal{A} = \{\alpha_1 = \text{判决为 } \omega_1, \alpha_2 = \text{判决为 } \omega_2\}$

有关概率信息 $\left\{ \begin{array}{l} (1) \Rightarrow \text{先验概率} \\ (2) \Rightarrow \text{类条件概率 } P(x = \text{阳性} | \omega_1) \\ (3) \Rightarrow \text{类条件概率 } P(x = \text{阳性} | \omega_2) \end{array} \right.$

确定： $R(\alpha_i | x = \text{阳性}), i = 1, 2$



解：设 $x = \text{“实验反应为阳性”}$ 。

(1) 类别状态 ω 有两种： $\omega = \omega_1$ 正常； $\omega = \omega_2$ 病患

判决结果与例1相反，影响判决结果的主导因素为“损失”。

(2) 根据已知，计算后验概率。

由条件1，状态先验概率： $P(\omega_1) = 0.995, P(\omega_2) = 0.005$

由条件2，条件概率： $P(x | \omega_1) = 0.01, P(x | \omega_2) = 0.95$

后验概率： $P(\omega_1 | x) = \frac{P(\omega_1)P(x | \omega_1)}{P(\omega_1)P(x | \omega_1) + P(\omega_2)P(x | \omega_2)} = 0.677$

$P(\omega_2 | x) = 1 - 0.677 = 0.323$

(3) 计算条件风险：

$R(\alpha_1 | x) = P(\omega_1 | x)\lambda_{11} + P(\omega_2 | x)\lambda_{12} = 0.677 \times 0.5 + 0.323 \times 6 = 2.2765$

$R(\alpha_2 | x) = P(\omega_1 | x)\lambda_{21} + P(\omega_2 | x)\lambda_{22} = 0.677 \times 2 + 0.323 \times 0.5 = 1.5155$

$R(\alpha_2 | x) < R(\alpha_1 | x)$

由最小风险判决，“阳性反应的甲”判决为 ω_2 (病患)，判决风险：1.5155



最小风险贝叶斯决策-小结

- 最小风险贝叶斯决策意义
- 最小风险贝叶斯决策规则
- 基于最小风险贝叶斯决策规则，对观测 x 的分类步骤

